

目录

图目录 IV

表目录 V

第 1 章 绪论 1

 1.1 研究背景及意义 1

 1.2 量子金融风险与收益分析的现状 2

 1.2.1 学术研究现状 2

 1.2.2 政策与产业现状 4

 1.3 本文研究内容与主要贡献 4

 1.4 论文章节安排 4

第 2 章 量子计算理论基础 5

 2.1 量子电路模型 5

 2.1.1 量子比特与量子态 5

 2.1.2 量子门 7

 2.1.3 量子电路 9

 2.1.4 量子测量 10

 2.2 基础量子算法 10

 2.2.1 量子傅里叶变换 10

 2.2.2 量子相位估计 12

 2.2.3 量子振幅估计 14

 2.3 本章小结 16

第 3 章 面向投资组合优化的量子线性求解框架 17

 3.1 概述 17

 3.2 投资组合优化的线性建模 18

 3.3 利用 HHL 算法解线性方程组 20

 3.3.1 HHL 算法简介 20

 3.3.2 线性方程组解的量子表示 21

 3.3.3 HHL 算法流程 21

3.3.4 投资组合优化对 HHL 算法的适配	23
3.4 用于降低方程组求解难度的约束缩放	23
3.4.1 矩阵条件数定义	23
3.4.2 基于约束缩放的等价变换	24
3.4.3 约束缩放系数的搜索算法	24
3.5 基于特征值的 HHL 算法电路设计	26
3.5.1 基于特征值的超参数设置	26
3.5.2 特征值估计模型	31
3.6 一般情况的额外处理	32
3.7 关于方法有效性的实验验证	34
3.7.1 实验配置	34
3.7.2 实验数据构建	35
3.7.3 相关工作对比	35
3.7.4 关于约束缩放系数鲁棒性的评估	38
3.7.5 关于特征值估计准确性的评估	39
3.8 本章总结	40
第 4 章 基于量子夏普利值估算的风险归因应用	42
4.1 概述	42
4.2 基于夏普利值的风险归因模型	43
4.2.1 风险度量指标的选择	43
4.2.2 基于合作博弈的风险归因建模	45
4.3 量子夏普利值估计算法	47
4.3.1 预先约定和说明	47
4.3.2 夏普利权重的量子积分近似	48
4.3.3 边际贡献的量子编码	53
4.3.4 算法整体演化与测量	54
4.4 风险节省博弈模型	56
4.4.1 次可加性与超可加性的根本矛盾	57
4.4.2 对偶转换策略	57

4.4.3 归因结果的还原机制 59

4.5 量子方案的实验验证 60

4.5.1 实验配置 60

4.5.2 实验数据集构建 61

4.5.3 理论框架正确性的数值验证 63

4.5.4 算法性能分析 65

4.6 本章小结 65

参考文献 66

作者简介 76

致 谢 77

图目录

图 2.1	布洛赫球	6
图 2.2	常见量子门图例	9
图 2.3	量子电路示例	10
图 2.4	QFT 的量子电路	12
图 2.5	QPE 完整量子电路	12
图 2.6	QPE 第一阶段的量子电路	13
图 2.7	Grover 算子 Q 的作用效果	15
图 3.1	投资组合的风险-收益曲线	18
图 3.2	HHL 算法的量子电路	21
图 3.3	使用下山单纯形法搜索约束缩放系数	26
图 3.4	基于特征值的超参数设置	27
图 3.5	λ 与 φ 关系的图形化解释	28
图 3.6	预测 $ \lambda _{\max}$ 和 $ \lambda _{\min}$ 的框架	32
图 3.7	资产时序数据的数据流过程	34
图 3.8	本文方法与 Qiskit HHL 实现 ^[1] 和混合 HHL 算法 ^[2] 的精度对比	38
图 3.9	关于静态约束缩放系数有效性的评估	39
图 3.10	特征值估计值的误差分析	40
图 3.11	$ \lambda _{\min}$ 和 $ \lambda _{\max}$ 真实值的分布	40
图 4.1	VaR 与 ES 值的对比	44
图 4.2	朴素等权分配和夏普利值对比	47
图 4.3	利用定积分的几何意义计算 $\beta(n, s)$ 近似值	50
图 4.4	制备采样点 $p'_{n_i}(k)$ 对应被积函数值的量子电路	52
图 4.5	三类资产池的累积净值与动态风险特征	63
图 4.6	使用 ES 直接计算与使用 RS 间接计算之间的误差	64

引用序号好像
有点问题

表目录

表 2.1 常见单比特门的矩阵形式 8

表 3.1 不同约束的均值-方差模型 19

表 3.2 不同模型用于预测 $|\lambda|_{\max}$ 和 $|\lambda|_{\min}$ 的表现 32

表 3.3 本文创新技术在各个数据集上的配置 35

表 3.4 不同算法实现的总体复杂度 Θ 对比 37

表 3.5 不同算法实现的具体电路复杂度对比 ($\epsilon = 1/8$) 37

表 4.1 不同风险资产池的统计特征 (2020 年 4 月至 2022 年 4 月) 62

表 4.2 超可加性验证结果统计 63

表 4.3 不同规模投资组合的资产采样配置 65

第 1 章 绪论

1.1 研究背景及意义

利用叠加态和纠缠态等量子力学独有的性质，量子计算机能够以与经典计算机根本不同的方式处理信息^[3,4]。基于这种独特的计算范式设计的多种量子算法已经展现出优于经典算法的理论优势：**Shor** 算法能够比已知最好的经典算法快指数倍地分解大整数，这对密码系统产生了深远影响^[5]；**Grover** 算法为非结构化搜索问题提供了二次加速，在数据库搜索和优化等领域具有应用潜力^[6]；用于求解线性方程组的量子算法（**HHL** 算法）对稀疏矩阵具备指数级加速能力，为各场景中的矩阵计算开辟了新的可能性^[7]。近年来，量子变分算法^[8]、量子退火算法^[9]等近似求解的算法模型也逐渐兴起。量子霸权的实验实现标志着量子计算发展的关键里程碑：国际上，“悬铃木”处理器在 200 秒内完成了超级计算机“顶点”需要计算 1 万年的随机电路采样任务^[10]；在国内，“九章”量子计算原型机则 1 分钟完成超级计算机“富岳”需 1 亿年完成的高斯玻色取样任务^[11]。

正是由于量子计算展现出的革命性的潜力，目前全球主要经济体都出台相应政策，并计划长期支持量子计算产业发展。国际上，美国颁布《国家量子倡议法案》，旨在确保美国在量子信息科学及其技术应用的领先地位，使量子技术服务于美国的经济和国家安全^[12]；加拿大的国家量子战略主要布局创新研究、人才生态、商业化应用，围绕量子计算机、量子软件、量子通信、量子传感器、量子材料等方向展开^[13]；欧盟委员会在十年内拨款 10 亿欧元，于 2018 年启动了欧洲量子旗舰计划^[14]；日本政府于 2018 年启动了量子飞跃计划，投资量子模拟与计算、量子传感器、超短脉冲激光三大领域^[15]。我国同样大力布局量子计算的基础研究和应用探索，在近两个五年计划中都提及要在量子信息领域组织未来产业孵化与加速计划，推动量子科技成为新的增长点^[16,17]。

金融行业是量子计算最具有应用潜力的产业之一^[18]。一方面，金融计算往往需要求解具有多项式甚至指数复杂度的复杂数学模型^[19]，而量子计算天然适用于这类数学模型；例如，变分量子算法适用于网点选址等二元优化模型^[20,21]，量子机器学习适用于风险管理、欺诈监测等场景^[22,23]，量子蒙特卡洛适用于期权定价等概率预测问题^[24,25]。另一方面，金融行业因其对计算效率、风险控制及收益

优化的追求,形成了对可落地解决方案持续的需求,这种需求与商业闭环的短暂性,使得量子计算一旦在特定金融场景中展现出理论或实验性优势,便可能迅速吸引投资并驱动其从实验室走向实际应用。金融行业的量子生态建设相较于其他行业更为积极:摩根大通、高盛集团、汇丰银行等国际金融巨头通过与量子计算公司合作的形式,进行了实际业务的量子计算试点^[26-29];在国内,新华财经同本源量子合作在其应用中上线量子金融服务^[30],中国工商银行、中国建设银行则分别在量子金融安全通信^[31]、量子金融优化应用^[32]上发力。

投资组合优化是金融行业最普遍的问题,旨在解决“如何将资金分配到不同资产上,才能达到最佳效果”。这里的“最佳”通常指两个目标之一:1)在可接受的风险水平下,追求收益最大化;2)在目标收益下,追求风险最小化。其理论基础源于马克维兹在1950年代提出的均值-方差模型^[33],根据不同的约束条件,则衍生出标准模型、托宾-夏普-林特纳模型、布莱克模型^[34]。随着量子线性求解器等量子算法的发明,使用量子计算进行投资组合优化成为了可能。量子算法可能突破经典算法的计算复杂度瓶颈,以应对资产规模快速增长的挑战,并在低计算功耗的条件下满足实时调仓等对计算速度的极致需求。研究投资组合优化的量子算法,符合国家关于发展未来产业、培育新增长点的战略导向,有助于在量子计算产业化国际竞争中赢得先机,为建立自主可控的量子金融生态系统奠定基础。

1.2 量子金融风险与收益分析的现状

1.2.1 学术研究现状

量子计算凭借其在处理高维空间、并行运算以及捕捉复杂相关性方面的潜力,正逐步重塑金融风险与收益分析的边界。当前的研究广泛覆盖了量化交易、投资组合优化、风险度量与风险评估等多个核心场景。

量化交易旨在获取市场的超额收益,这依赖于对市场动态的精准捕捉与快速执行。结合高斯混合模型处理连续数据后,Song等人实验证明了隐量子马尔可夫模型能够有效捕捉金融市场的叠加与纠缠动态,在股票指数的抗噪预测上优于经典模型^[35]。在交易策略与执行层面,Ciceri等人利用真实的量子硬件生成投影量子特征映射来暴露出隐藏的市场信号,可使机构债券订单成交概率的样本外预测实现大幅跃升^[36]。针对外汇交易环境,利用量子长短期记忆网络进行趋势

预测,并结合量子强化学习智能体,Chen 等人以极少的可训练参数实现稳健的风险调整后回报^[37]。在高频量化交易场景中,Zhuang 等人利用量子相位估计结合量子线性回归开发的协整检验算法,将寻找套利对的复杂度大幅降低,实现了二次加速^[38]。

1. 金融风险度量与衍生品定价

在市场风险评估中,研究表明利用门级量子计算机结合量子幅度估计(QAE)算法,能够以近乎平方级的加速计算在险价值(VaR)和条件在险价值(CVaR),显著优于经典蒙特卡洛模拟(Woerner 和 Egger, 2019)。为进一步优化资源消耗,将衍生品定价预言机引入叠加态并应用量子信号处理(QSP)框架,能在保持渐近复杂度不变的前提下,将实现量子优势所需的逻辑时钟频率要求降低达 30 倍(Stamatopoulos 等, 2024)。然而,理论优势在落地真实业务时面临挑战。针对非正态经验分布和 Copula 依赖性分离的研究指出,受限于目前的量子噪声和较小的比特规模,基于 QAE 的风险测量在应对大规模资产组合时,尚未展现出超越成熟经典模拟的商业优势,且业界全面迁移的驱动力目前较弱(Wilkens 和 Moorhouse, 2023)。

2. 信用评估、欺诈检测与系统性风险

在面对隐蔽且极度不平衡的金融数据时,量子机器学习展现出了独特的特征提取能力。针对银行业不同类别贷款的信用风险评估,通过融合量子计算的高维处理效率与经典深度学习构建的混合模型,有效提升了分类的准确性与细粒度(Rath 和 Date, 2025)。与之类似,基于中性原子量子处理器的二次无约束二值优化(QUBO)采样,能够仅用 50 个弱学习器达到与 1200 棵经典随机森林树相近的信用降级预测精度(Leclerc 等, 2023)。在反欺诈领域,结合拓扑数据分析与变分量子电路(VQC)构建的浅层量子图神经网络(QGNN),在极少量量子比特下便表现出显著优于经典 GraphSAGE 模型的准确率(Innan 等, 2024)。更为宏观地,应对金融网络受冲击后崩盘预测这类 NP-hard 问题,可以通过将机构破产模型映射为自旋量子哈密顿量基态,利用量子退火器进行求解(Orús 等, 2019)。尽管上述混合模型具有创新性,但硬件固有的噪声、短相干时间,以及为了适应当前算力而进行的数据降维与网络简化,极大限制了其泛化能力与实际可解释性。

3. 投资组合风险-收益优化

投资组合优化是权衡风险与收益的绝对核心，学者们在此领域展开了多维度的算法设计与硬件验证。纯量子算法尝试通过直接制备大规模历史收益序列的量子态，实现了关于资产数量多项式对数级时间复杂度的最优风险收益曲线采样 (Rebentrost 和 Lloyd, 2024)。为了更细致地刻画现实市场，引入偏度和峰度等高阶风险矩的投资组合问题被转化为高阶无约束二值优化(HUBO)模型，并成功映射至 QAOA 算法求解 (Uotila 等, 2025)。应对多期动态调整，基于经典 Helmbold 算法改写的量子在线组合优化算法，利用量子内积估计实现了与资产数量无关的单期交易更新成本 (Lim 和 Rebentrost, 2024)。在特定硬件部署层面，研究者验证了物理级离散时间量子行走 (Quantum Walk) 在组合优化网络中寻找最优资产节点的可行性 (Qu 等, 2024)，并证明了利用趋势比率 (TR) 结合 D-Wave 量子退火机可以有效应对多国股票指数的复杂动态管理 (Chou 等, 2024)。为了进一步提升收敛效率，提出利用经典连续松弛问题的全局最优解来限制量子离散搜索空间的“热启动”策略，有效减少了所需的量子比特数 (Schlütter 等, 2026)。

然而，量子组合优化的实际效用正遭遇严峻的实证挑战。通过引入“专家分析评估”框架对 QAOA 和 VQE 输出进行校验发现，单纯数学层面极小化成本函数得出的组合，往往违背金融业界的风控常识与多样化原则 (Innan 等, 2025)。大规模的基准测试也表明，在相同运行时间下，针对问题定制的经典启发式算法性能始终优于现有量子方法，经典混合整数规划 (MIP) 通常能在数秒内求出最优解 (Stopfer 和 Wagner, 2025)。此外，针对容错架构下二阶锥规划的端到端资源分析证实，基于量子线性系统求解器的量子内点法 (QIPM) 由于其极高的常数开销与庞大的 T 门深度，目前并未能展现出比最先进经典求解器更快的速度 (Dalzell 等, 2023)。

1.2.2 政策与产业现状

1.3 本文研究内容与主要贡献

1.4 论文章节安排

第2章 量子计算理论基础

2.1 量子电路模型

目前有量子电路、量子退火等诸多量子计算模型^[39]，大多数量子算法都基于量子电路模型设计。类似经典的布尔电路，量子电路由多个量子比特和一系列量子门构成，并在最后对量子比特进行读取，即“测量”操作。特定的量子比特初始化步骤、量子门序列，以及对测量结果的后处理，是量子算法的重要要素。

2.1.1 量子比特与量子态

单量子比特系统 经典比特可表示一个布尔值，且只会有唯一的取值——0或1。在量子计算中，我们用狄拉克符号 $|0\rangle$ 和 $|1\rangle$ 来表示这两种状态，两者是 $\mathbb{C}^2$ 空间中的一组基态：

$$|0\rangle = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad |1\rangle = \begin{bmatrix} 0 \\ 1 \end{bmatrix} \quad (2.1)$$

量子比特具有叠加性，单个量子比特的取值各有一定概率取值为 $|0\rangle$ 或 $|1\rangle$ ：

$$|\phi\rangle = \alpha|0\rangle + \beta|1\rangle \quad (2.2)$$

其中， $|\phi\rangle$ 是单个量子比特的量子态； α 和 β 被称为振幅，两者满足关系 $|\alpha|^2 + |\beta|^2 = 1$ ，表示该量子比特有 $|\alpha|^2$ 概率处于状态 $|0\rangle$ ，有 $|\beta|^2$ 概率处于状态 $|1\rangle$ 。

单量子比特系统可以通过布洛赫球^[4]进行可视化表示。由于 $\alpha, \beta \in \mathbb{C}$ ，可令

$$\alpha = e^{i\varphi_1} \cos \frac{\theta}{2}, \quad \beta = e^{i\varphi_2} \sin \frac{\theta}{2} \quad (2.3)$$

其中 φ_1 和 φ_2 是两个状态上的相位。将式 (2.3) 代入式 (2.2)，可得

$$|\phi\rangle = e^{i\varphi_1} \cos \frac{\theta}{2} |0\rangle + e^{i\varphi_2} \sin \frac{\theta}{2} |1\rangle \quad (2.4)$$

若只考虑相位差 $\varphi = \varphi_2 - \varphi_1$ ，那么式 (2.4) 可表达为

$$|\phi\rangle = \cos \frac{\theta}{2} |0\rangle + e^{i\varphi} \sin \frac{\theta}{2} |1\rangle \quad (2.5)$$

其中 $\theta \in [0, \pi]$ ， $\varphi \in [0, 2\pi]$ 。如图 2.1，通过 θ 和 φ 两个自由度，可定位单位

球面上的一个点，原点至该点的向量即可表示单个量子比特的状态。




图 2.1 布洛赫球

多量子比特系统 我们首先以双量子比特系统为例，阐述如何表达多量子比特系统。由于量子叠加性，双量子比特系统有 4 个基态：

$$|00\rangle = \begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \end{bmatrix}, \quad |01\rangle = \begin{bmatrix} 0 \\ 1 \\ 0 \\ 0 \end{bmatrix}, \quad |10\rangle = \begin{bmatrix} 0 \\ 0 \\ 1 \\ 0 \end{bmatrix}, \quad |11\rangle = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 1 \end{bmatrix} \quad (2.6)$$

一个双量子比特系统可表达为

$$|\phi\rangle = \alpha_{00}|00\rangle + \alpha_{01}|01\rangle + \alpha_{10}|10\rangle + \alpha_{11}|11\rangle \quad (2.7)$$

同样满足 $|\alpha_{00}|^2 + |\alpha_{01}|^2 + |\alpha_{10}|^2 + |\alpha_{11}|^2 = 1$ 。

扩展到 n 个量子比特的系统，则可以表达为

$$|\phi\rangle = \sum_{i=0}^{2^n-1} \alpha_i |i\rangle \quad (2.8)$$

多量子比特系统仍然满足

$$\sum_{i=0}^{2^n-1} |\alpha_i|^2 = 1 \quad (2.9)$$

式 (2.8) 中 $|i\rangle$ 为 $\mathbb{C}^{2^n}$ 空间的基态，其向量表示中第 $i+1$ 个元素为 1，其余全 0。例如 $\mathbb{C}^4$ 空间的基态 $|2\rangle$ 的向量表示为 $[0, 0, 1, 0]^T$ 。有时也会将 $|i\rangle$ 写成二进制的形式，例如式 (2.7) 表示的双量子比特系统的基态。

在量子电路模型中,可以将一些具有相同作用的量子比特归为一组,抽象地称为**量子寄存器**。

量子态间的计算 根据式 (2.8), n 个量子比特构成的系统的基态是固定的,因此可以用仅包含振幅信息的向量表达该系统:

$$|\phi\rangle = \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_{2^n-1} \end{bmatrix} \quad (2.10)$$

基于此可定义对偶的量子态:

$$\langle\phi| = [\alpha_0^*, \alpha_1^*, \dots, \alpha_{2^n-1}^*] \quad (2.11)$$

这里再引入一量子态 $|\psi\rangle = [\beta_0, \beta_1, \dots, \beta_{2^n-1}]^T$ 。对于两个量子态 $|\phi\rangle$ 和 $|\psi\rangle$,可做内积,形式和向量内积相同:

$$\langle\phi|\psi\rangle = \sum_{i=0}^{2^n-1} \alpha_i^* \beta_i \quad (2.12)$$

特别的,根据式 (2.9),量子态与自身做内积,有

$$\langle\phi|\phi\rangle = 1 \quad (2.13)$$

另一个常用的运算是张量积,即 $|\phi\rangle \otimes |\psi\rangle$,这是克罗内克积的一种特殊形式,也可简写为 $|\phi\rangle|\psi\rangle$:

$$|\phi\rangle \otimes |\psi\rangle = \begin{bmatrix} \alpha_0|\psi\rangle \\ \alpha_1|\psi\rangle \\ \vdots \\ \alpha_{2^n-1}|\psi\rangle \end{bmatrix} \quad (2.14)$$

需要明确的是,不同于内积,张量积并不要求两个量子态的量子比特数相等。实际上,量子比特所描述的状态数量在数学上通过张量积的形式不断扩张:量子比特数分别为 m 和 n 的量子系统的状态向量各有 2^m 和 2^n 个元素,意味着两者的张量积有 $2^m \times 2^n = 2^{m+n}$ 个元素。随着量子比特不断加入量子系统,即在数学上不断进行张量积运算,量子系统可表达的状态数量指数级增加,这是量子计算优越性在数学上的体现。

2.1.2 量子门

量子门的矩阵表示 经典的布尔电路上有与、或、非等门操作，在量子计算中，也存在类似的量子门。基于第2.1.1小节，量子态可表达为向量；通过矩阵乘向量的形式，可实现量子态的演化，量子门就是该矩阵在量子计算中的具象化。我们一般用矩阵 U 表示一个通用的量子门，那么 $|\phi'\rangle = U|\phi\rangle$ 就是一次量子态演化。

类似对偶量子态的定义，可定义矩阵 U 的伴随矩阵 $U^\dagger$ 为 U 各个元素取共轭并整体进行转置，即 $U^\dagger = (U^*)^T$ 。相应地， $U|\phi\rangle$ 的对偶态为 $\langle\phi|U^\dagger$ 。为了满足式(2.13)的要求，表示量子门的矩阵必须为酉矩阵，满足 $U^\dagger U = I$ 。

单比特门 单个量子比特的状态向量只有两个元素，因此表示单比特门的矩阵大小都为 2×2 。表2.1列出了常见的单比特门。

表 2.1 常见单比特门的矩阵形式

单比特门名称	矩阵形式
哈达玛门 (H 门)	$H = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$
泡利 X 门	$X = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$
泡利 Y 门	$Y = \begin{bmatrix} 0 & -i \\ i & 0 \end{bmatrix}$
泡利 Z 门	$Z = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}$
X 旋转门 (R_X 门)	$R_X(\theta) = \begin{bmatrix} \cos \frac{\theta}{2} & -i \sin \frac{\theta}{2} \\ -i \sin \frac{\theta}{2} & \cos \frac{\theta}{2} \end{bmatrix}$
Y 旋转门 (R_Y 门)	$R_Y(\theta) = \begin{bmatrix} \cos \frac{\theta}{2} & -i \sin \frac{\theta}{2} \\ \sin \frac{\theta}{2} & \cos \frac{\theta}{2} \end{bmatrix}$
Z 旋转门 (R_Z 门)	$R_Z(\theta) = \begin{bmatrix} e^{-i\frac{\theta}{2}} & 0 \\ 0 & e^{i\frac{\theta}{2}} \end{bmatrix}$

H 门一般用于将单一状态的量子比特转换为叠加态：

$$H|0\rangle = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \frac{|0\rangle + |1\rangle}{\sqrt{2}} \quad (2.15)$$

X 、 Y 、 Z 门是一组泡利门，分别对应向量在布洛赫球上绕 x 、 y 、 z 轴旋转 180° 。其中， X 门使用最为广泛，用于翻转量子比特的状态，因此又被形象地称为量子非门：

$$X(\alpha|0\rangle + \beta|1\rangle) = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} \alpha \\ \beta \end{bmatrix} = \begin{bmatrix} \beta \\ \alpha \end{bmatrix} = \beta|0\rangle + \alpha|1\rangle \quad (2.16)$$

$$X|0\rangle = |1\rangle, \quad X|1\rangle = |0\rangle$$

R_X 、 R_Y 、 R_Z 这三个旋转门可以认为是泡利门的推广，分别对应向量在布洛赫球上绕 x 、 y 、 z 轴旋转角度 θ 。

多比特门 顾名思义，多比特门是同时作用于多个量子比特的量子门。受控门是使用最广泛的一类多比特门。最典型的受控门是 **CNOT** 门，也称 **CX** 门。如图 2.2 所示，**CNOT** 门同时作用于两个量子比特，其中有一个量子比特控制位，当控制位状态为 $|1\rangle$ 时，对受控位量子比特执行 X 门。需要注意的是，由于量子比特处于叠加态，是否对受控位执行 X 门是概率性事件。**Toffoli** 门则有两个控制位，当且仅当两个控制位都为 $|1\rangle$ 时，才对受控位执行 X 门。




图 2.2 常见量子门图例

除了受控门外，**SWAP** 门是另一种常见的多比特门，用于交换两个量子比特的状态。

2.1.3 量子电路

量子电路是表达量子计算算法或程序的一种方式。量子电路将一组量子比特经由一系列量子门演化的过程图形化地展现了出来。以图 2.3 为例，该量子电路有三个量子比特，初始状态都为 $|0\rangle$ ，依次作用了 H 门、 T 门、**CNOT** 门、 S

门等量子门。




图 2.3 量子电路示例

电路深度是评估量子电路复杂度的重要概念。直观地说，图 2.3 的电路中，每个由蓝色区间分割的区块内，所有电路门都可并行执行，称为“一步”，电路深度是量子电路执行所需的最小步数。

可以证明，所有酉变换都可转化成单比特门和 CNOT 门的组合^[4]。举例来说，图 2.3 就是 Toffoli 门的电路分解。**量子电路编译**的过程之一就是将程序员编写的电路分解为单比特门和 CNOT 的组合。

2.1.4 量子测量

测量、迹、偏迹

2.2 基础量子算法

本节将概要性地介绍基础量子算法。量子傅里叶变换 (quantum Fourier transform, QFT) 是众多量子算法的核心子电路^[4,5]。量子相位估计 (quantum phase estimation, QPE) 是构建 HHL 算法电路并应用于投资组合优化的重要组件^[7]，同时也是本文优化方案的研究对象之一 (第 3 章)。量子振幅估计 (quantum amplitude estimation, QAE) 旨在以二次加速的优势估算目标量子态的概率^[40]，且已有金融场景应用，如期权定价的量子算法使用 QAE 计算期权收益期望^[24,25]，而本文则利用 QAE 进行风险归因值的提取 (第 4 章)。

2.2.1 量子傅里叶变换

QFT 与离散傅里叶变换 (discrete Fourier transform, DFT) 的数学形式有相似之处，是 DFT 在波函数振幅上的量子实现。DFT 以复向量 $\{x_j\}_{j=0}^{N-1}$ 作为输入，输出复向量 $\{y_k\}_{k=0}^{N-1}$ ：

$$y_k = \frac{1}{\sqrt{N}} \sum_{j=0}^{N-1} x_j e^{\frac{2\pi i j k}{N}} \quad (2.17)$$

QFT 是定义在标准正交基 $\{|j\rangle\}_{j=0}^{N-1}$ 上的酉变换:

$$|j\rangle \xrightarrow{\text{QFT}} \frac{1}{\sqrt{N}} \sum_{k=0}^{N-1} e^{\frac{2\pi i j k}{N}} |k\rangle \quad (2.18)$$

结合式 (2.17) 和式 (2.18), QFT 对任意量子态的作用可以表示为:

$$\sum_{j=0}^{N-1} x_j |j\rangle \xrightarrow{\text{QFT}} \sum_{k=0}^{N-1} y_k |k\rangle \quad (2.19)$$

在傅里叶变换中, N 是 2 的幂, 这里取 $N = 2^n$, 其中 $n = 1, 2, \dots$ 。我们把基态写成二进制形式, 以便于接下来对 QFT 电路的解释。基态 $|j\rangle$ 表示为 $|j_1 j_2 \dots j_n\rangle$, 即 $j = 2^{n-1}j_1 + 2^{n-2}j_2 + \dots + 2^0 j_n$, 并用 $0.j_l j_{l+1} \dots j_n$ 表示小数 $2^{-1}j_l + 2^{-2}j_{l+1} + \dots + 2^{-(n-l+1)}j_n$ 。有以下 QFT 的乘积形式:

$$\begin{aligned} |j_1 j_2 \dots j_n\rangle \xrightarrow{\text{QFT}} & \frac{1}{\sqrt{2^n}} (|0\rangle + e^{2\pi i 0.j_n} |1\rangle) (|0\rangle + e^{2\pi i 0.j_{n-1} j_n} |1\rangle) \\ & \dots (|0\rangle + e^{2\pi i 0.j_1 \dots j_n} |1\rangle) \end{aligned} \quad (2.20)$$

图 2.4 是 QFT 的量子电路, 为方便表示, 规定线路自上到下为高位到低位, 其中量子门 R_k 表示酉变换:

$$R_k = \begin{bmatrix} 1 & 0 \\ 0 & e^{\frac{2\pi i}{2^k}} \end{bmatrix}, \quad k = 2, 3, \dots, n \quad (2.21)$$

对 $|j_1\rangle$ 执行 H 门后, 电路量子态为:

$$\frac{1}{\sqrt{2}} (|0\rangle + e^{2\pi i 0.j_1} |1\rangle) |j_2 \dots j_n\rangle \quad (2.22)$$

因为当 $j_1 = 1$ 时, $e^{2\pi i 0.j_1} = -1$, 否则为 1。执行受控 R_2 后, 得到:

$$\frac{1}{\sqrt{2}} (|0\rangle + e^{2\pi i 0.j_1 j_2} |1\rangle) |j_2 \dots j_n\rangle \quad (2.23)$$

因为当 $j_2 = 1$ 时, 会执行 R_2 门, 将 e 的指数除以 2^2 , 否则量子态不变。继续执行受控 R_3 门、 R_4 门直至 R_n 门, 得到量子态:

$$\frac{1}{\sqrt{2}} (|0\rangle + e^{2\pi i 0.j_1 j_2 \dots j_n} |1\rangle) |j_2 \dots j_n\rangle \quad (2.24)$$

其余线路上的量子比特与 $|j_1\rangle$ 同理, $|j_1 j_2 \dots j_n\rangle$ 经过图 2.4 所示的电路, 再插

入若干 SWAP 门交换第 i 条和第 $n - i + 1$ 条线路上的量子比特，即可得 QFT 的乘积形式。




图 2.4 QFT 的量子电路

2.2.2 量子相位估计

假设酉矩阵 U 对应于特征向量 $|\mu\rangle$ 的特征值为 $e^{2\pi i \varphi}$ ，QPE 用于估计 φ 的值。其中， φ 称为相位，满足

$$0 \leq \varphi < 1 \quad (2.25)$$

QPE 的量子电路如图 2.5 所示，可以看到 QPE 分为两个阶段：第一阶段执行 H 门和受控 U^{2^j} 门，第二阶段执行逆 QFT 操作。




图 2.5 QPE 完整量子电路

我们把第一阶段单独拆解开看，其电路细节如图 2.6 所示，寄存器 Q_p 存储相位估计值，寄存器 Q_u 存储特征向量 $|\mu\rangle$ 。

Q_p 中所有比特执行 H 门后，得到量子态：

$$\frac{1}{\sqrt{2^n}} (|0\rangle + |1\rangle)^{\otimes n} |\mu\rangle \quad (2.26)$$

由于 $U|\mu\rangle = e^{2\pi i \varphi} |\mu\rangle$ ，对寄存器 Q_p 中比特执行受控酉变换 U^{2^j} ，得：

$$\frac{1}{\sqrt{2^n}} \left(|0\rangle + e^{2\pi i 2^{n-1} \varphi} |1\rangle \right) \left(|0\rangle + e^{2\pi i 2^{n-2} \varphi} |1\rangle \right) \dots \left(|0\rangle + e^{2\pi i 2^0 \varphi} |1\rangle \right) \quad (2.27)$$




图 2.6 QPE 第一阶段的量子电路

假设 φ 可以表示为 n 比特, 即 $\varphi = 0.\varphi_1\varphi_2\cdots\varphi_n$, 则式 (2.27) 可以写成

$$\begin{aligned} & \frac{1}{\sqrt{2^n}} \left(|0\rangle + e^{2\pi i 0.\varphi_n} |1\rangle \right) \left(|0\rangle + e^{2\pi i 0.\varphi_{n-1}\varphi_n} |1\rangle \right) \\ & \dots \left(|0\rangle + e^{2\pi i 0.\varphi_1\varphi_2\cdots\varphi_n} |1\rangle \right) \end{aligned} \quad (2.28)$$

式 (2.28) 与式 (2.20) 中基态经过 QFT 后的数学形式相同, 因此可以直接使用逆 QFT 变换得到 $|\varphi\rangle$ 。

值得注意的是, 酉矩阵 U 的特征向量 $|\mu\rangle$ 一般也是未知的, 因此也难以在寄存器 Q_u 中编码特征向量。当在 Q_u 中编码任意向量 $|\nu\rangle$ 时, 假设该向量可以分解为

$$|\nu\rangle = \sum_j \nu_j |\mu_j\rangle \quad (2.29)$$

QPE 的结果是对应相位的概率叠加:

$$\sum_j \nu_j |\varphi_j\rangle \quad (2.30)$$

2.2.3 量子振幅估计

QAE 的细节不在本文的讨论范畴之内, 因此本小节将忽略部分细节, 对 QAE 及其变体的原理进行框架性介绍。

最早期的 QAE 是在 QPE 的基础之上改造而来, 且兼具 Grover 算法^[6]的思想。首先, 定义状态制备算子 $\mathcal{A}$, 将其作用于 $|0\rangle$, 得到目标态 $|\Psi_1\rangle$ 与其正交态 $|\Psi_0\rangle$ 的叠加:

$$\mathcal{A}|0\rangle = \sqrt{1-a}|\Psi_0\rangle + \sqrt{a}|\Psi_1\rangle \quad (2.31)$$


我们称这一状态 $\mathcal{A}|0\rangle$ 为初始态, a 就是我们需要估算的概率, 故 $|\Psi_1\rangle$ 称为目标态。可以发现, 无论系统的总量子比特数有多少, $\mathcal{A}|0\rangle$ 始终被限制在由 $|\Psi_0\rangle$ 和 $|\Psi_1\rangle$ 张成的二维平面内。如果我们定义一个角度 θ , 使得 $\sin \theta = \sqrt{a}$, 那么上述叠加态就可以直观地写为

$$\mathcal{A}|0\rangle = \cos \theta |\Psi_0\rangle + \sin \theta |\Psi_1\rangle \quad (2.32)$$

为了提取角度 θ , 算法引入了 Grover 迭代算子 $\mathcal{Q} = -\mathcal{A}\mathcal{S}_0\mathcal{A}^{-1}\mathcal{S}_\chi$, 算子各部分的意义如下:

- $\mathcal{S}_\chi$ 能识别出目标态 $|\Psi_1\rangle$, 即 $\mathcal{S}_\chi|\Psi_1\rangle = -|\Psi_1\rangle$, 而对非目标态 $|\Psi_0\rangle$ 保持不变;
- $\mathcal{S}_0$ 只对全零初始态进行相位翻转, 即 $\mathcal{S}_0|0\rangle = -|0\rangle$, 对其他任何正交态都不做改变。

在几何上, $\mathcal{S}_\chi$ 相当于向量在二维平面中沿 $|\Psi_0\rangle$ 轴进行一次反射, 而 $-\mathcal{A}\mathcal{S}_0\mathcal{A}^{-1}$ 相当于向量沿着初始态 $\mathcal{A}|0\rangle$ 的方向进行了一次反射。如图 2.7 所示, 这两次二维平面内的反射, 等价于一次旋转。因此, Grover 算子 $\mathcal{Q}$ 的本质是一个旋转矩阵, 它每次作用在初始态上, 都会让状态向量在由 $|\Psi_0\rangle$ 和 $|\Psi_1\rangle$ 构成的二维平面内旋转角度 2θ 。可以证明, 具有这一旋转特性的矩阵在这个二维空间内的特征值必定是 $e^{\pm i2\theta}$ ^[40]。因此, 我们只需要利用 QPE, 提取出 $\mathcal{Q}$ 的特征相位, 就能反向计算出 θ , 进而得到概率 a 。

图 2.7 Grover 算子 Q 的作用效果

在当前量子硬件条件下, 受限于量子比特的相干时间与量子门保真度, 学界衍生出了多种无 QPE 的优化版本:

- 最大似然量子振幅估计 (maximum likelihood quantum amplitude estimation, ML-QAE)^[41] 将概率提取转移到经典后处理阶段, 该方法构造了一系列不同深度的浅层 Grover 幂次电路 Q^m , 测量其处于目标态的概率, 并利用经典的极大似然估计对这些独立电路的测量结果进行全局拟合, 从而反推出概率;
- 快速量子振幅估计 (faster quantum amplitude estimation, F-QAE)^[42] 采用“两阶段”策略求解目标相位, 从代数层面解决了后处理反余弦计算的歧义, 且算法在达到了查询复杂度的海森堡极限的同时, 针对常数项进行了优化;
- 迭代量子振幅估计 (iterative quantum amplitude estimation, I-QAE)^[43] 仅依赖多轮纯 Grover 迭代, 不需要 QPE 第二阶段的 QFT[†], 而是通过经典的迭代后处理收缩置信区间, 此外算法采用贪心策略自适应地调整迭代步长以应对后处理中的反余弦计算歧义。

在 QAE 中, 需要多次调用 Grover 算子 Q , 一次调用称为一次采样。所谓 QAE 的二次加速, 即为在相同误差 ε 下, QAE 的采样数为 $O(\varepsilon^{-1})$, 而通过直接测量的采样数为 $O(\varepsilon^{-2})$ 。

2.3 本章小结

量子电路模型作为当前量子计算的主流框架，本章首先详细阐述了量子电路模型中量子比特、量子门、量子电路等重要概念，并对量子电路深度、量子电路编译等名词做了简单介绍。随后，本章介绍了一系列基础量子算法，包括量子傅里叶变换、量子相位估计、量子振幅估计，为本文后续的论证奠定了基础。

第3章 面向投资组合优化的量子线性求解框架

3.1 概述

在各类金融应用中，投资组合优化无疑是最重要的问题之一，它确定每个资产的最佳投资权重，以平衡风险和回报。简单来说，投资组合优化的目的是要在确定未来收益时，风险最小化；或者在确定未来风险时，收益最大化。举例来说，图 3.1 中的点 P （绿色点）是最优点：在固定收益 E^* 下，点 P 的风险最小；在固定风险 V^* 下，点 P 的收益最大；而对于其余两个红点，都有比他们收益更大或风险更小的点 P 。

投资组合优化的量子方法可以分为伊辛求解和线性求解。通过将解限制为二进制值，投资组合优化可以转化为二次无约束二元优化（quadratic unconstrained binary optimization, QUBO）问题。在量子系统中，QUBO 可表示为伊辛模型，通过量子退火、量子变分等手段求解^[44-46]。在该场景中，资产持有状态通过量子比特 $|0\rangle$ 和 $|1\rangle$ 的叠加态来表述，最终持有策略由测量获得。另一方面，线性求解首先将投资组合优化表达为线性方程组，HHL 算法将线性方程组的矩阵和向量投影到量子态，计算投资权重^[47,48]。

尽管量子计算具有显著的并行性，但现有的量子解决方案难以兼具可扩展性和精确性。伊辛求解只能给出“持有”或“不持有”的策略，换句话说，伊辛求解缺乏量化每个资产投资权重的能力，导致投资组合优化的精确性较低。相比之下，线性求解因为能给出投资权重，天然就比伊辛求解的精确性高。然而，线性求解在电路规模方面表现出难以承受的计算复杂性；例如，涉及 2 个资产的 HHL 算法电路^[7]，经过 Qiskit 编译^[49] 后的电路深度超过 3.7×10^8 。尽管有混合 HHL 算法这一类 HHL 算法的变体，试图通过在电路中插入经典运算来降低电路复杂度^[2,48,50]，但这类方法特别依赖输入线性方程组的数值特性，仍需要大量量子比特获得准确的特征值。

现有量子算法的之所以存在上述局限性，是因为没有从金融问题及其关联的数据样本入手进行优化。针对投资组合优化，伊辛求解仅使用二进制的粗粒度编码方案，导致投资建议过于简单。现有线性求解则受限于线性系统的复杂性：来自于真实市场数据的线性方程组，其矩阵的条件数过大。具体来说，条件

数在 HHL 算法的渐进复杂度中充当平方项^[7], 而对于 2 资产的投资组合优化, 条件数就可达到 10^5 量级。即使使用混合 HHL 方法^[2,48,50], 也因为过大的条件数难以获得较好的特征值估计精度, 导致最终资产权重向量的低精确度。

为了克服上述困难, 本文提出了一种**面向投资组合优化的量子线性求解框架**。本框架的新颖之处在于利用金融理论和数据来优化 HHL 算法电路的设计。我们首先观察到, 由真实市场数据构造的线性方程组, 其矩阵的条件数通常很大, 会显著增加电路复杂性, 从而降低算法的可扩展性。为了解决这一问题, 本文提出了一种**等效变换技术**, 通过约束缩放的形式使等效矩阵的条件数大幅降低。接下来, 为进一步提升计算精度, 本文设计了一套**基于特征值的超参数选取方案**, 该方案仅利用矩阵的两个特征值先验, 完成所有超参数的计算。本文用极简的支持向量回归模型做了这两个特征值的预测, 在最终的资产配比向量上取得了相较于已有量子算法更高的精确度。




图 3.1 投资组合的风险-收益曲线

3.2 投资组合优化的线性建模

马克维兹提出, 利用均值和方差表示投资组合的收益和风险, 通过这两者的平衡来获得最佳投资配比 $\mathbf{w} = [w_1, w_2, \dots, w_n]^T$ ^[33]。首先, 对于 n 个资产在过去 T 个时间片内的收益, 可定义为向量

$$\mathbf{r}_t = [r_1^t, r_2^t, \dots, r_n^t]^T, t = 1, 2, \dots, n \quad (3.1)$$

基于此, 可计算过去 T 个时间片内的历史收益均值 $\mathbf{R}$ 和方差 Σ :

$$\begin{aligned}
\mathbf{R} &= \mathbb{E}(\mathbf{r}_t) \approx \frac{1}{T} \sum_{t=1}^T \mathbf{r}_t \\
\Sigma &= \mathbb{V}(\mathbf{r}_t) \approx \frac{1}{T-1} \sum_{t=1}^T (\mathbf{r}_t - \mathbf{R})(\mathbf{r}_t - \mathbf{R})^T
\end{aligned} \tag{3.2}$$

而对于资产配比为 $\mathbf{w}$ 的未来，预期收益和风险计算方式如下：

$$\begin{aligned}
E &= \mathbf{w}^T \mathbf{R} \\
V &= \mathbf{w}^T \Sigma \mathbf{w}
\end{aligned} \tag{3.3}$$

基于这个思想，问题的目标函数为最小化风险 $\mathbf{w}^T \Sigma \mathbf{w}$ ，而固定的预期收益可以看作约束 $\mathbf{w}^T \mathbf{R} = E$ 。

针对不同场景，均值-方差模型对投资配比也有不同的约束^[34]，表 3.1 中列出了常见的约束模型。

表 3.1 不同约束的均值-方差模型

名称	约束
标准模型	$\sum_{i=1}^n w_i = 1$ $w_i \geq 0$
托宾-夏普-林特纳模型	$\sum_{i=1}^n w_i = 1 + w_{n+1}$ $w_i \geq 0, \quad i = 1, 2, \dots, n$ $w_{n+1} \geq -1$
布莱克模型	$\sum_{i=1}^n w_i = 1$

在本文中，选择布莱克模型进行求解，原因是该模型为等式约束，更适用于线性建模。因此，投资组合优化的数学形式确定如下：

$$\begin{aligned}
&\min_{\mathbf{w}} \mathbf{w}^T \Sigma \mathbf{w} \\
&\text{s.t. } \mathbf{w}^T \mathbf{R} = E \\
&\quad \mathbf{w}^T \mathbf{1} = 1
\end{aligned} \tag{3.4}$$

其中, $\mathbf{1}$ 表示所有元素全为 1 的向量。

定理 3.1 求解投资组合优化的最优资产配比, 等价于求解如下线性方程组:

$$\begin{bmatrix} 0 & 0 & \mathbf{R}^T \\ 0 & 0 & \mathbf{1}^T \\ \mathbf{R} & \mathbf{1} & \Sigma \end{bmatrix} \begin{bmatrix} \eta \\ \rho \\ \mathbf{w} \end{bmatrix} = \begin{bmatrix} E \\ 1 \\ \mathbf{0} \end{bmatrix} \quad (3.5)$$

证明 依据式 (3.4), 可得到如下等价形式:

$$\begin{aligned} \min_{\mathbf{w}} \quad & \frac{1}{2} \mathbf{w}^T \Sigma \mathbf{w} \\ \text{s.t.} \quad & \mathbf{w}^T \mathbf{R} = E \\ & \mathbf{w}^T \mathbf{1} = 1 \end{aligned} \quad (3.6)$$

引入拉格朗日乘子 η 和 ρ , 构造拉格朗日函数, 得

$$L(\mathbf{w}, \eta, \rho) = \frac{1}{2} \mathbf{w}^T \Sigma \mathbf{w} + \eta(\mathbf{w}^T \mathbf{R} - E) + \rho(\mathbf{w}^T \mathbf{1} - 1) \quad (3.7)$$

对 $\mathbf{w}$ 、 η 、 ρ 分别求梯度, 并令结果为零, 得到 3 组方程:

$$\begin{cases} \frac{\partial L}{\partial \mathbf{w}} = \Sigma \mathbf{w} + \eta \mathbf{R} + \rho \mathbf{1} = \mathbf{0} \\ \frac{\partial L}{\partial \eta} = \mathbf{w}^T \mathbf{R} - E = 0 \\ \frac{\partial L}{\partial \rho} = \mathbf{w}^T \mathbf{1} - 1 = 0 \end{cases} \quad (3.8)$$

将上述 3 组方程稍作整理, 即可得线性方程组, 证毕。 $\square$

我们将式 (3.5) 中的矩阵记作 M_0 。

3.3 利用 HHL 算法解线性方程组

3.3.1 HHL 算法简介

Harrow、Hassidim、Lloyd 三人共同提出了求解线性方程组的量子算法, 故称 HHL 算法^[7]。HHL 算法用于求解线性方程组 $A\mathbf{x} = \mathbf{b}$, 算法要求 A 必须为厄米矩阵、 $\mathbf{b}$ 为单位向量。HHL 算法的渐进时间复杂度为 $O(\log N \kappa^2 \varepsilon^{-1})$ ^[7], 其中 N 是矩阵阶数, ε 是指定的精确度, κ 为矩阵条件数。

图 3.2 是 HHL 算法的量子电路, 由 Q_v 、 Q_p 、 Q_a 三个量子寄存器组成, 其中 Q_v 、 Q_p 分别有 n_v 、 n_p 个量子比特, 而 Q_a 只有一个量子比特:

- Q_v 用于加载向量 $\mathbf{b}$ 并存储最终的解向量 $\mathbf{x}$;
- Q_p 用于存储 QPE 的输出, 并作为控制位执行 R_Y 旋转门;
- Q_a 存储辅助比特, 当且仅当最终测量结果为 $|1\rangle$ 时, HHL 算法执行成功。




图 3.2 HHL 算法的量子电路

3.3.2 线性方程组解的量子表示

对于形如 $A\mathbf{x} = \mathbf{b}$ 的线性方程组, 其解为 $\mathbf{x} = A^{-1}\mathbf{b}$, 在量子计算中表示为

$$|x\rangle = A^{-1}|b\rangle \quad (3.9)$$

由于 A 为厄米矩阵, 可对其进行谱分解^[4]:

$$A = \sum_{j=0}^{N-1} \lambda_j |\mu_j\rangle\langle\mu_j| \quad (3.10)$$

其中, λ_j 为 A 的特征值, $|\mu_j\rangle$ 为对应的特征向量。 $|\mu_j\rangle$ 可作为一组标准正交基, 对 $|b\rangle$ 进行分解:

$$|b\rangle = \sum_{j=0}^{N-1} \beta_j |\mu_j\rangle \quad (3.11)$$

将式 (3.10) 和式 (3.11) 代入式 (3.9), 可得解的量子表示:

$$|x\rangle = \sum_{j=0}^{N-1} \frac{\beta_j}{\lambda_j} |\mu_j\rangle \quad (3.12)$$

3.3.3 HHL 算法流程

通过如图 3.2 所示的量子电路可以看到, HHL 算法大致分为向量加载、QPE、受控选择、逆 QPE、辅助比特测量五个步骤, 接下来将逐一对各个步骤的量子态演化进行数学推导。

在未作用任何量子门前，所有量子比特都默认为 $|0\rangle$ ：

$$|\psi\rangle = |0\rangle^{\otimes n_v} |0\rangle^{\otimes n_p} |0\rangle \quad (3.13)$$

我们需要在向量加载这一步将 $\mathbf{b} = [b_0, b_1, \dots, b_{N-1}]$ 各个元素作为振幅编码到量子态中：

$$|b\rangle = \sum_{j=0}^{N-1} b_j |j\rangle \quad (3.14)$$

一般通过等距变换实现类似式 (3.14) 的振幅编码^[51]。由于式 (3.11) 和式 (3.14) 都可视为 $|b\rangle$ 的分解，因此对于向量加载后的系统，量子态可以等价写为

$$|\psi\rangle = \sum_{j=0}^{N-1} \beta_j |\mu_j\rangle |0\rangle^{\otimes n_p} |0\rangle \quad (3.15)$$

此后执行 QPE，QPE 所用的矩阵为 $U = e^{iAt} = \sum_{j=0}^{N-1} e^{i\lambda_j t} |\mu_j\rangle \langle \mu_j|$ ，其中 t 称为矩阵演化时间。QPE 最终会输出相位的叠加态：

$$|\psi\rangle = \sum_{j=0}^{N-1} \beta_j |\mu_j\rangle |\varphi_j\rangle |0\rangle \quad (3.16)$$

由于 $\{|\mu_j\rangle\}_{j=0}^{N-1}$ 是一组标准正交基，故 $U|\mu_j\rangle = e^{i\lambda_j t} |\mu_j\rangle$ 。因此， $e^{i\lambda_j t}$ 和 $|\mu_j\rangle$ 分别是 U 的特征值和特征向量。根据第 2.2.2 小节介绍，对于 QPE 输出的相位 φ_j ， $\{e^{2\pi i \varphi_j}\}_{j=0}^{N-1}$ 是 U 的特征值。所以，必须满足

$$e^{i\lambda_j t} = e^{2\pi i \varphi_j} \quad (3.17)$$

观察式 (3.17)，可以发现 φ_j 和 λ_j 存在某种关联关系。换句话说，可以利用式 (3.17) 以及 Q_p 中存储的相位信息，提取出 A 的特征值信息，而具体的提取手段也是本文的创新点之一，将在第 3.5 节详细阐述。

如果默认在 QPE 后已得到 λ_j ，那么在执行受控旋转时，可指定旋转角度为 $\theta = 2 \arcsin \frac{C}{\lambda_j}$ ，经过受控旋转，量子态为

$$|\psi\rangle = \sum_{j=0}^{N-1} \beta_j |\mu_j\rangle |\varphi_j\rangle \left(\sqrt{1 - \frac{C^2}{\lambda_j^2}} |0\rangle + \frac{C}{\lambda_j} |1\rangle \right) \quad (3.18)$$

此处的 C 称为归一化常数，用于保证式 (3.18) 中辅助比特的振幅小于等于 1。然后用逆 QPE 解纠缠，得到

$$|\psi\rangle = \sum_{j=0}^{N-1} \beta_j |\mu_j\rangle |0\rangle^{\otimes n_p} \left(\sqrt{1 - \frac{C^2}{\lambda_j^2}} |0\rangle + \frac{C}{\lambda_j} |1\rangle \right) \quad (3.19)$$

最后测量辅助比特，假设成功测量得到 $|1\rangle$ ， Q_v 这组量子比特的状态就坍缩为

$$\frac{1}{\sqrt{\sum_{j=0}^{N-1} \frac{\beta_j^2}{\lambda_j^2}}} \sum_{j=0}^{N-1} \frac{\beta_j}{\lambda_j} |\mu_j\rangle \quad (3.20)$$

相比式 (3.12)，式 (3.20) 说明，最终得到的量子态是 $|x\rangle$ 标准化后的向量。一般来说，最终的量子态会经由特殊设计的测量矩阵进行某些期望计算，而不会通过多次的采样获得完整的经典解向量^[47]。

直接提取

Statevector

3.3.4 投资组合优化对 HHL 算法的适配

如第 3.3.1 小节所述，HHL 算法对输入的线性方程组 $Ax = b$ 有其硬性要求。对比式 (3.4) 的线性方程组。不难发现，式 (3.5) 中矩阵 M_0 因其对称性，满足 HHL 算法的需求。至于其中的向量，即使不是单位向量，可将输入的向量变换为 $\frac{b}{\|b\|}$ ，最后将解向量乘以 $\|b\|$ 。因此，可以方便地用 HHL 算法求解式 (3.5)。

然而，在实际构建 HHL 算法电路时，对方程组矩阵的阶数表示也有具体的要求：由于方程组的向量 b 必须用量子态的振幅表示，因此 b 的元素个数必须为 2 的幂，这导致方程组矩阵 A 的阶数必须也为 2 的幂。假设有 n 个资产，则 M_0 的阶数为 $n+2$ ，因此要求 $n+2$ 也为 2 的幂。显然， $n+2$ 在大多数情况下不会是 2 的幂。为使具体技术的阐述更明晰，后续第 3.4 节和第 3.5 节暂时针对 $n+2$ 为 2 的幂的情况进行讨论，并在第 3.6 节对一般情况进行了扩展。

3.4 用于降低方程组求解难度的约束缩放

3.4.1 矩阵条件数定义

对于矩阵 M_0 的所有特征值组成的集合 $\{\lambda_j\}$ ，我们定义：

$$|\lambda|_{\min} = \min\{|\lambda| \mid \lambda \in \{\lambda_j\}\}, \quad |\lambda|_{\max} = \max\{|\lambda| \mid \lambda \in \{\lambda_j\}\} \quad (3.21)$$

矩阵 M_0 的条件数定义如下：

$$\kappa = \frac{|\lambda|_{\max}}{|\lambda|_{\min}} \quad (3.22)$$

数学上, 条件数用于衡量使用近似算法进行矩阵求逆的难度^[52]。若 $\kappa = 1$, 表明这是一个等距变换矩阵。若条件数更大, 则代表用共轭梯度法^[53]等迭代近似算法求解时, 需要更多的迭代次数以获得相同的精确度。对于 HHL 算法来说, 其渐进时间复杂度为 $O(\log N \kappa^2 \varepsilon^{-1})^{[7]}$, κ 在其中作为平方项, 也体现了“求解复杂度与条件数多项式级别正相关”的特点。一般情况下, HHL 算法被认为是指数级的加速; 然而, 投资组合优化的矩阵 M_0 , 条件数通常可达到 10^5 量级, 在计算算法复杂度时成为一个不可忽略的常数项。

3.4.2 基于约束缩放的等价变换

传统的方法通过缩放按行或者列缩放矩阵以减小条件数^[54]。然而, 这种缩放不能保持问题等价性, 线性方程组的解难以还原。本文不直接改造矩阵, 而是从投资组合优化的数学形式本身出发, 通过两个约束缩放系数 s_1 和 s_2 生成新的等价矩阵。引入约束缩放系数的形式如下:

$$\begin{aligned} \min_{\mathbf{w}} \quad & \mathbf{w}^T \Sigma \mathbf{w} \\ \text{s.t.} \quad & s_1 \mathbf{w}^T \mathbf{R} = s_1 E \\ & s_2 \mathbf{w}^T \mathbf{1} = s_2 \end{aligned} \quad (3.23)$$

相较于式 (3.4), 式 (3.23) 在等式约束两边同时乘以相同的系数, 并不破坏相等的性质, 因此两者的解相等。同样采用拉格朗日乘数法, 可得如下的线性方程组:

$$\begin{bmatrix} 0 & 0 & s_1 \mathbf{R}^T \\ 0 & 0 & s_2 \mathbf{1}^T \\ s_1 \mathbf{R} & s_2 \mathbf{1} & \Sigma \end{bmatrix} \begin{bmatrix} \eta \\ \rho \\ \mathbf{w} \end{bmatrix} = \begin{bmatrix} s_1 E \\ s_2 \\ \mathbf{0} \end{bmatrix} \quad (3.24)$$

记式 (3.24) 中矩阵为 M_1 。

约束缩放系数提供了降低矩阵条件数的可能性。经验上, 我们测试了良好的约束缩放系数可以指数级地减小条件数——从 10^5 减小至 ~ 10 。

3.4.3 约束缩放系数的搜索算法

最佳的约束缩放系数对于不同的 M_0 显然是不同的，这主要取决于资产的数量及其数值特征。若为每一个矩阵计算其最佳的约束缩放系数，计算约束缩放系数这一前置步骤的复杂度就已经超过后续求解式(3.24)的线性方程组，得不偿失。因此，我们试图找到一个针对特定数据集的静态约束缩放系数，这组系数能在平均意义上最大程度降低矩阵条件数。

我们从一组特定的市场数据集中生成一系列投资组合优化矩阵 M_0 。基于此，可定义自变量是 s_1 和 s_2 ，目标函数是这一批矩阵应用约束缩放系数 s_1 和 s_2 后的条件数的平均值。接下来，我们设计算法来搜索将条件数最小化的静态约束缩放系数。

本文基于下山单纯形算法^[55]来迭代地搜索约束缩放系数。如图3.3(a)所示，我们用一个二维平面来表示 s_1 和 s_2 所属空间，平面上的一点就代表一组约束缩放系数。算法首先在平面上初始化三个点 $\mathbf{x}_1^0$ 、 $\mathbf{x}_2^0$ 、 $\mathbf{x}_3^0$ ，作为最初候选的几组约束缩放系数。可以发现，三个点在平面上勾勒出了一个三角形区域。在每一次迭代中，我们会根据上一次迭代的三角形生成一系列候选点。图3.3(b)是生成的候选点的一个例子，图中每个候选点($\mathbf{x}_{m_1}$ 、 $\mathbf{x}_{m_2}$ 、 $\mathbf{x}_{cc}$ 、 $\mathbf{x}_c$ 等)都是所在线段的中点。实际的情况相比图3.3(b)中的例子复杂很多，根据下山单纯形算法的优化规则，各个候选点的距离会进行进一步的缩放^[56]。在历次迭代中，算法逐渐抛弃上一次迭代中差的（相较于其他点，应用该点的约束缩放系数后平均条件数更大）点，保留上一次迭代最优秀的点并添加优秀的候选点（相较于其他点，应用该点的约束缩放系数后平均条件数更小）组成新的三角形区域。经历几次迭代后，三角形会如图3.3(a)所示收缩到优秀的区域中，这时我们选择三角形中最好的点作为最终的约束缩放系数。




图 3.3 使用下山单纯形法搜索约束缩放系数

3.5 基于特征值的 HHL 算法电路设计

3.5.1 基于特征值的超参数设置

HHL 算法同输入矩阵特征值密切相关，主要体现在如下两点：

- 从 HHL 算法的时间复杂度看，如第 3.3.1 小节所述，输入矩阵条件数是复杂度的平方项，而基于式 (3.22)，条件数由特征值的比值决定；
- 从 HHL 算法的执行流程看，如第 3.3.3 小节所述，HHL 算法的 QPE 模块用于提取输入矩阵的特征值，在受控旋转阶段的常数取值同特征值大小相关。

因此，特征值的先验知识天然地可以指导 HHL 算法的电路设计。举个极端的例子，若已知所有特征值，就可直接省去 QPE 步骤，大幅减少电路复杂度，并且计算精度相比使用由 QPE 提取的特征值更高。然而，分析所有的特征值需要花费巨大的计算成本，这会破坏量子优势，简化的特征值估计方案又难以得到足够的信息^[57,58]。本文的核心洞见在于，HHL 算法主要与 $|\lambda|_{\max}$ 和 $|\lambda|_{\min}$ 相关，本文尝试利用这两者来指导 HHL 算法电路上的超参数取值。

定义 $|\lambda|_{\max}^M$ 为矩阵 M 所有特征值取绝对值后的最大值， $|\lambda|_{\min}^M$ 同理。图 3.4 展示了基于 $|\lambda|_{\max}^M$ 和 $|\lambda|_{\min}^M$ 进行超参数取值的设计，本节后续内容将对这些取值的合理性进行论证。




图 3.4 基于特征值的超参数设置

矩阵预处理 我们首先要求, HHL 算法输入矩阵的所有特征值满足

$$|\lambda| < 1 \quad (3.25)$$

对于已完成约束缩放后的矩阵 M_1 , 我们需要对其做缩放, 得到 HHL 算法输入矩阵:

$$M_2 = \frac{l}{|\lambda|_{\max}^{M_1}} M_1, \quad l \in (0, 1) \quad (3.26)$$

其中, l 为一常数。 M_1 除以 $|\lambda|_{\max}^{M_1}$ 后, 其特征值绝对值的极大值为 1, 因此还需要乘以区间位于 $(0, 1)$ 的系数以满足式 (3.25)。在本文中, 取 $l = \frac{1}{2}$, 在二进制的角度, 正好将特征值的二进制表示移动一位, 不容易造成 QPE 的精度损失。经过缩放后, M_1 的所有特征值都会同步乘以 M_1 的缩放系数 $\frac{l}{|\lambda|_{\max}^{M_1}}$, 而条件数由于等比例缩放并不会改变, 最终 M_2 的特征值的绝对值落于 $[\frac{1}{2\kappa}, \frac{1}{2}]$ 。

矩阵演化时间 如第 3.3.3 小节所述, QPE 所需矩阵通过一个演化时间 t 得到, 且满足式 (3.17)。在此, 我们取 $t = \pi$, 即将式 (3.17) 特化为

$$e^{2\pi i \varphi} = e^{i\pi \lambda} \quad (3.27)$$

接下来, 将利用式 (3.27), 进行“相位提取为特征值”这一行为的推导。

在复数域中, 若 $e^x = e^y$, 则指数 x 和 y 并不一定相等, 而是相差 $2\pi i$ 的整数倍, 相当于向量在复平面上旋转 360° 。根据式 (3.27), 有:

$$2\pi i \varphi = i\pi \lambda + 2k\pi i, \quad k \in \mathbb{Z} \quad (3.28)$$

消除公共因子 $i\pi$ 并整理, 得

$$\lambda = 2(\varphi - k) \quad (3.29)$$

由于 λ 和 φ 分别满足式 (3.25) 和式 (2.25) 表示的约束, 可得如下映射关系

$$\lambda = \begin{cases} 2\varphi, & 0 \leq \varphi < \frac{1}{2} \\ 2(\varphi - 1), & \frac{1}{2} < \varphi < 1 \end{cases} \quad (3.30)$$

图 3.5 形象地展示了这种关系。图中蓝色线为 $\varphi \in [0, 1)$, 黄色线为 $\lambda \in (-1, 1)$, 要使得式 (3.27) 成立, 必须实部和虚部都相等。当 $\varphi < \frac{1}{2}$ 时, 只会在 $\lambda < 0$ 的区间内找到相等点; 同理, 当 $\varphi > \frac{1}{2}$ 时, 只会在 $\lambda > 0$ 的区间内找到相等点; $\varphi = \frac{1}{2}$ 则不需要纳入考虑, 可以发现在 $(-1, 1)$ 区间内不会出现相等点, 即 QPE 不会输出相位 $\frac{1}{2}$ 。

本文取 $t = \pi$, 在矩阵缩放后, 实现了特征值和相位的一一映射, 相比其他方案有如下优势:

- 固定取 $t = 2\pi$ [1,2,50], 会出现相位重叠 (比如 $\lambda = -0.1$ 和 $\lambda = 0.9$ 同时映射到 $\varphi = 0.9$), 一种方法多引入一个量子比特作为符号位^[1], 但无疑增加了电路复杂度;
- 执行多次 QPE 尝试得到最优的演化时间^[48], 增加了执行量子电路的次数, 而本文方案只需在求解线性方程组时执行一次 QPE 即可。




图 3.5 λ 与 φ 关系的图形化解释

QPE 量子比特数 QPE 使用 n_p 个量子比特近似表示相位, 后续步骤会将相位利用式 (3.30) 解析为特征值。接下来将通过合理的近似, 推导能够将最终解向

量计算精度控制在 $\|\mathbf{x} - \tilde{\mathbf{x}}\| \leq \varepsilon$ 以内的 n_p 最小值。其中, $\mathbf{x}$ 为解向量精确值, $\tilde{\mathbf{x}}$ 为 HHL 算法得到的解向量, ε 为两者绝对误差的上界。

假设 3.1 ε 是认为设置的小量, 这意味着 QPE 使用足够的量子比特数, 因此可以认为解析得到的特征值 $\tilde{\lambda}$ 与精确值 λ 近似相等。

引理 3.1 QPE 提取得到的特征值倒数的相对误差在近似意义上不超过解向量的绝对误差 ε 。

证明 由式 (3.20), 可得

$$\begin{aligned} |x\rangle &= \frac{1}{\sqrt{\sum_{j=0}^{N-1} \frac{\beta_j^2}{\lambda_j^2}}} \sum_{j=0}^{N-1} \frac{\beta_j}{\lambda_j} |\mu_j\rangle \\ |\tilde{x}\rangle &= \frac{1}{\sqrt{\sum_{j=0}^{N-1} \frac{\beta_j^2}{\tilde{\lambda}_j^2}}} \sum_{j=0}^{N-1} \frac{\beta_j}{\tilde{\lambda}_j} |\mu_j\rangle \end{aligned} \quad (3.31)$$

基于假设 3.1, 略去部分误差项, 绝对误差可以写为

$$\begin{aligned} \| |x\rangle - |\tilde{x}\rangle \| &\approx \left\| \frac{1}{\sqrt{\sum_{j=0}^{N-1} \frac{\beta_j^2}{\lambda_j^2}}} \sum_{j=0}^{N-1} \beta_j \left(\frac{1}{\lambda_j} - \frac{1}{\tilde{\lambda}_j} \right) |\mu_j\rangle \right\|^2 \\ &= \frac{1}{\sum_{j=0}^{N-1} \frac{\beta_j^2}{\lambda_j^2}} \sum_{j=0}^{N-1} \beta_j^2 \left(\frac{1}{\lambda_j} - \frac{1}{\tilde{\lambda}_j} \right)^2 \leq \varepsilon^2 \end{aligned} \quad (3.32)$$

对于任意特征值, 设特征值倒数的最大误差为 Δ , 有:

$$\begin{aligned} \forall j = 0, 1, \dots, N-1 \quad &\left| \frac{\frac{1}{\lambda_j} - \frac{1}{\tilde{\lambda}_j}}{\frac{1}{\lambda_j}} \right| \leq \Delta \\ \Leftrightarrow &\left(\frac{1}{\lambda_j} - \frac{1}{\tilde{\lambda}_j} \right)^2 \leq \frac{\Delta^2}{\lambda_j^2} \end{aligned} \quad (3.33)$$

将式 (3.33) 代入式 (3.32), 得

$$\| |x\rangle - |\tilde{x}\rangle \| \leq \frac{1}{\sum_{j=0}^{N-1} \frac{\beta_j^2}{\lambda_j^2}} \sum_{j=0}^{N-1} \beta_j^2 \frac{\Delta^2}{\lambda_j^2} = \Delta^2 \leq \varepsilon^2 \quad (3.34)$$

证得

$$\left| \frac{\frac{1}{\lambda} - \frac{1}{\tilde{\lambda}}}{\frac{1}{\lambda}} \right| \leq \varepsilon \quad (3.35)$$

□

引理 3.2 基于假设 3.1 和引理 3.1, 可得 λ 的相对误差也近似为 ε 。

证明

$$\left| \frac{\lambda - \tilde{\lambda}}{\lambda} \right| \approx \left| \frac{\lambda - \tilde{\lambda}}{\tilde{\lambda}} \right| = \left| \frac{\frac{1}{\tilde{\lambda}} - \frac{1}{\lambda}}{\frac{1}{\tilde{\lambda}}} \right| \leq \varepsilon \quad (3.36)$$

□

定理 3.2 至少需要 $\lceil 2 + \log_2 \frac{\varepsilon}{\kappa} \rceil$ 个量子比特, 使得解向量绝对误差控制在 ε 以内。

证明 由于使用 n_p 个量子比特进行近似, 近似值 $\tilde{\varphi}$ 和精确值 φ 的绝对误差必然不会超过 2^{-n_p} 。依据式 (3.30), λ 和 $\tilde{\lambda}$ 的误差不会超过 2^{1-n_p} :

$$|\lambda - \tilde{\lambda}| \leq 2^{1-n_p} \quad (3.37)$$

此外, M_1 经缩放得到 M_2 后, 有

$$|\lambda|_{\min}^{M_2} = \frac{1}{2\kappa} \quad (3.38)$$

将式 (3.37) 和式 (3.38) 代入式 (3.36), 得

$$\left| \frac{\lambda - \tilde{\lambda}}{\lambda} \right| = \frac{|\lambda - \tilde{\lambda}|}{|\lambda|} \leq 2^{2-n_p\kappa} \leq \varepsilon \quad (3.39)$$

故

$$n_p \geq 2 + \log_2 \frac{\varepsilon}{\kappa} \quad (3.40)$$

□

由于 $\kappa = |\lambda|_{\max}^{M_1} / |\lambda|_{\min}^{M_1}$ ，本文令

$$n_p = 2 + \left\lceil \log_2 \frac{|\lambda|_{\max}^{M_1}}{|\lambda|_{\min}^{M_1} \varepsilon} \right\rceil \quad (3.41)$$

归一化常数 根据式 (3.19)，可以得到两个对归一化常数的取值思路：

- 一方面，促成该量子态利用了旋转门，旋转角度为 $\theta = 2 \arcsin \frac{C}{\lambda_j}$ ，要在数学上满足 $\arcsin$ 定义域，必须符合 $|C| \leq |\lambda|_{\min}^{M_2}$ 这一要求；
- 另一方面，要保证 HHL 算法尽可能成功，即辅助比特为 $|1\rangle$ 的概率大，要求 $|C|$ 尽可能大。

因此，本文取 $|C|$ 的上限，令

$$C = |\lambda|_{\min}^{M_2} = \frac{1}{2\kappa} = \frac{|\lambda|_{\min}^{M_1}}{2|\lambda|_{\max}^{M_1}} \quad (3.42)$$

3.5.2 特征值估计模型

特征值估计是数学领域中一个被广泛研究的课题，通常应用数值逼近或统计方法来快速估算特征值^[57-59]。然而，对于用于解决投资组合优化问题的 HHL 算法而言，传统方法提供的特征值信息不足或不适用。例如，仅用于预测协方差矩阵 (M_1 的一个子矩阵) 的特征值，且需要预先知道特征值的重数^[57]；仅能估计某个区间内的特定值的特征值数量^[58]；旨在计算出所有特征值，但导致巨大的计算成本^[59]。本文设计了一种估计 $|\lambda|_{\max}^{M_1}$ 和 $|\lambda|_{\min}^{M_1}$ 的架构，它能够利用历史市场数据，在无需任何先验知识的情况下快速估计特征值。该模型是依赖于数据集的，并且可以进行离线训练，从而极大地减轻了经典计算部分的压力。

如图 3.6 所示，我们采用支持向量回归 (support vector regression, SVR) 作为我们的基础预测模型。从式 (3.24) 中的矩阵出发，我们将 $s_1 R$ 的所有元素与 Σ 的上三角部分拼接成一个向量，并将该向量作为 SVR 模型的输入。训练数据是根据资产价值从历史市场数据中收集的。然后，我们枚举这些资产的各种组合，并计算精确的特征值作为训练数据集。此外，为了减轻浮点数的截断误差，我们引入了一个可调参数 α 。例如，在真实的 $|\lambda|_{\min}$ 极小的情况下，有限位宽的浮点数难以区分训练标签中的差异；此时，将 $\alpha - |\lambda|_{\min}$ 调整为一个较大的值可以放大

训练标签之间的绝对差异，从而有助于构建更准确的模型。




图 3.6 预测 $|\lambda|_{\max}$ 和 $|\lambda|_{\min}$ 的框架

我们还尝试了决策树和深度学习等其他方法作为基础模型。参考表 3.2 中列出的结果可以发现，其他三种模型带来的性能提升有限，却伴随着不成比例的高计算复杂度。**SVR** 模型的有效性在于其出色的泛化性能，这一点已在基于股票预选的投资组合优化研究中得到证实^[60-62]。由于 **SVR** 的计算复杂度独立于输入空间的维度^[63]，该预测方法在一定程度上避免了大规模训练带来的计算瓶颈，从而保留了量子优势。

表 3.2 不同模型用于预测 $|\lambda|_{\max}$ 和 $|\lambda|_{\min}$ 的表现

模型	参数数量	操作数	ℓ_2 -损失 ($ \lambda _{\max}, \lambda _{\min}$)
支持向量回归 ^[64]	1640	1.6×10^3	0.39, 0.033
决策树 ^[65]	1969	2×10^2	1.66, 0.066
多层感知机 ^[66]	2137	2×10^3	0.024, 0.034
LeNet ^[67]	20411	2×10^4	15.8, 0.088

3.6 一般情况的额外处理

对于 n 个资产的投资组合优化，其矩阵阶数为 $n+2$ ；而如第 3.3.4 小节所述，矩阵阶数必须为 2 的幂。若 $n+2$ 不是 2 的幂，本文通过扩张矩阵的方式，得到阶数为 $2^{\lceil \log_2(n+2) \rceil}$ 的厄米矩阵：

$$\begin{bmatrix} 0 & 0 & \mathbf{R}^T & \mathbf{0}^T \\ 0 & 0 & \mathbf{1}^T & \mathbf{0}^T \\ \mathbf{R} & \mathbf{1} & \Sigma & \mathbf{0}^T \\ 0 & 0 & 0 & I \end{bmatrix} \begin{bmatrix} \eta \\ \rho \\ \mathbf{w} \\ 0 \end{bmatrix} = \begin{bmatrix} E \\ 1 \\ 0 \\ 0 \end{bmatrix} \quad (3.43)$$

相比式 (3.5) 表示的线性方程组，式 (3.43) 在矩阵的右下角添加了一个单位矩阵，其余扩展的位置填 0，这种扩张矩阵的方式不影响 $\mathbf{w}$ 的解，记扩张后的矩阵为 M'_0 。


第3.4节提出的约束缩放仍然使用，且由于矩阵扩张，还可在 M'_0 引入新的约束系数 s^* ：

$$\begin{bmatrix} 0 & 0 & s_1 \mathbf{R}^T & \mathbf{0}^T \\ 0 & 0 & s_2 \mathbf{1}^T & \mathbf{0}^T \\ s_1 \mathbf{R} & s_2 \mathbf{1} & \Sigma & \mathbf{0}^T \\ \mathbf{0} & \mathbf{0} & \mathbf{0} & s^* I \end{bmatrix} \begin{bmatrix} \eta \\ \rho \\ \mathbf{w} \\ \mathbf{0} \end{bmatrix} = \begin{bmatrix} s_1 E \\ s_2 \\ \mathbf{0} \\ \mathbf{0} \end{bmatrix} \quad (3.44)$$


相比原有约束缩放系数的搜索方法，现有方法需要遵循下山单纯形算法的候选点规则，在三维立体空间中搜索。记引入约束缩放系数后的矩阵为 M'_1 。这里必须规定 $s^* \neq 0$ 以使 M'_1 满秩。

第3.5节利用矩阵的特征值进行了参数设计，由于 M'_1 满秩， $|\lambda|_{\max}^{M'_1}$ 和 $|\lambda|_{\min}^{M'_1}$ 存在，这套方案仍然使用。并且，特征值预测框架本身是针对特定资产数量的，因此也适用于扩展后的矩阵 M'_1 。

图3.7展示了在一般情况下，利用第3.4节和第3.5节所述方法的数据流转。这里分为两个过程：在训练阶段，获得固定的约束缩放系数 s_1 、 s_2 和 s^* ，以及静态的特征值估计模型，该过程是离线的；在后续的多资产投资组合优化阶段，会利用离线训练的约束缩放系数简化矩阵、利用特征值估计模型的输出构造 HHL 算法量子电路。图3.7举例的是3资产的情况。我们收集了多个资产每日调整后的收盘价作为原始数据，从中随机选择3个资产来构建一系列投资组合以及相应的矩阵 M'_0 。然后，利用第3.4节所述的搜索方法，得到适用于这一数据集的约束缩放系数。最后，将所有投资组合矩阵应用约束缩放系数得到矩阵 M'_1 ，利用 NumPy^[68] 计算特征值对矩阵进行标注，得到了用于训练特征值估计模型的矩阵及其特征值标签。后续进行资产的投资组合优化，同构造训练数据过程相同，先通过计算相邻日期的增量来建立收益表，再利用式(3.2)，获得历史预期收益向量和协方差矩阵，进而构建矩阵 M_0 。由于约束缩放系数已经预先通过搜索得到，因此可直接应用约束缩放系数得到矩阵 M'_1 。同理，特征值估计模型也已离线训练完成，可直接输出特征值的估计值指导 HHL 算法的量子电路设计。



(a) 构造 3 资产投资组合优化数据用于离线训练



(b) 利用约束缩放和特征值估计优化 3 资产投资组合优化的量子求解过程

图 3.7 资产时序数据的数据流过程

3.7 关于方法有效性的实验验证

3.7.1 实验配置

量子算法实现 本文的量子计算部分基于 Qiskit^[69] 开发。QPE 部分和受控 R_Y 门是通过 Qiskit 中的 PhaseEstimation 和 UCRYGate 实现的。Qiskit 转译器 (transpiler)^[49] 的优化级别设置为 0。用于约束缩放系数搜索的方法扩展自 SciPy 库^[70]。用于特征值估计的 SVR 模型是使用 Scikit-Learn 库^[71] 实现的。表 3.3 给出了本文在每个数据集上的配置。

实验环境 所有程序均在配备 2TB RAM、64 核 3.75GHz CPU 的服务器上，于 Ubuntu 22.04.4 LTS 环境下执行。

3.7.2 实验数据构建

从三个具有代表性的证券交易所构建数据集，包括纳斯达克交易所 (Nasdaq)、纽约证券交易所 (NYSE) 和美国证券交易所 (AMEX)。每个交易所的股票数量列于表 3.3 中。由于模拟 HHL 电路的巨大复杂性，我们考虑资产数量从 2 个到 6 个的投资组合优化问题。

表 3.3 本文创新技术在各个数据集上的配置

交易所数据	数据规模	约束缩放系数			特征值估计模型	
		s_1	s_2	搜索迭代次数	$\alpha - \lambda _{\min}$	$\alpha - \lambda _{\max}$
Nasdaq	3100	0.56	1.9e-3	119	3000	100
NYSE	400	0.25	3.2e-4	152	5000	800
AMEX	40	0.28	6.6e-4	125	4000	400

所有实验均从特定交易所数据中采样资产构成投资组合，并对本文设计的量子投资组合优化流程应用对应的配置项。

3.7.3 相关工作对比

本小节设计了电路复杂度和解向量精度两个指标。首先，我们通过统计消耗和量子资源和电路深度，从空间和时间两个维度对复杂度进行建模。根据第 3.3.1 小节，量子比特的总数是三组量子比特的总和：

$$N^q = n_v + n_p + n_a \quad (3.45)$$

此外，我们使用 N^{CNOT} 和 N^d 分别表示 Qiskit 转译后的 CNOT 门数量和电路深度。这是因为 CNOT 门是大多数现有量子设备上的主要误差来源^[72]，而电路深度同样也是评估量子算法执行时间的重要指标。综上所述，复杂度指标制定如下：

$$\Theta = N^q + \lg N^{\text{CNOT}} + \lg N^d \quad (3.46)$$

在此，我们对 N^{CNOT} 和 N^d 取对数，因为这两项随着量子比特数的增加呈指数级增长，若不采取对数方案，会导致 N^q 对复杂度几乎没有影响。

精度则通过量化 NumPy 计算的资产配比 $\mathbf{w}$ 与量子算法计算的 $\tilde{\mathbf{w}}$ 之间的差

异来评估。因此，我们根据余弦相似度制定了精度公式：

$$\Delta = \frac{1}{2} \left(1 + \frac{\mathbf{w}^T \tilde{\mathbf{w}}}{\|\mathbf{w}\| \|\tilde{\mathbf{w}}\|} \right) \quad (3.47)$$

可以发现， Δ 始终落于区间 $[0, 1]$ 内。其值越接近 1，表示计算越准确。

我们将与三种 HHL 实现进行比较：原始 HHL 算法^[7]、Qiskit HHL 实现^[1] 和混合 HHL 算法^[2]。Rebentrost 等人^[47] 提出了应用原始 HHL 求解布莱克模型的想法，但没有具体的参数化，也没有进行实验。因此，在与原始 HHL 算法比较时，我们假设特征值已经预先精确地计算好，仅比较量子电路复杂度指标。在 Qiskit HHL 实现中，受控旋转门是使用 ExactReciprocal 实现的。混合 HHL 算法在量子电路中间插入测量，并伴随一些经典操作。由于这种方法涉及经典计算和量子计算，我们将其命名为混合方法。Qiskit HHL 实现和混合 HHL 算法都需要指定 QPE 模块的量子比特数，无法自适应地平衡量子电路复杂度和解向量精度。因此，我们仅在 QPE 量子比特数相同的情况下与它们比较精度指标。

表 3.4 展示了式 (3.46) 定义的总复杂度 Θ ，而表 3.5 比较了具体所需的量子比特数、电路深度和 CNOT 门数量。总体而言，在绝对误差 ε 从 $1/16$ 到 $1/4$ 的范围内，本文实现了约 34.64% 至 36.94% 的复杂度降低。在 $\varepsilon = 1/8$ 的情况下，我们列出了详细的资源消耗，其中本文的方法对量子资源有显著的减少，特别是量子门的数量（对于 2 资产投资组合优化实现了最大 99.996% 的减少）。根据式 (3.40)，这种资源节省源于得益于约束缩放技术降低了矩阵条件数。对于较小的 ε ，复杂度降低幅度略有减少，这是由于式 (3.46) 计算复杂度时的对数函数所致。我们发现，在处理 3 资产投资组合优化时，平均复杂度显著较高。这源于该维度下部分实验矩阵存在极大的条件数，极值拉高了整体算术平均值。为了消除离群点的影响，我们进一步计算了中位数值（见表底注）。3 资产复杂度的中位数为 23.94，介于 2 资产（21.05）和 4 资产（24.30）之间，符合复杂度随资产规模温和增长的趋势，说明该中位数更能代表 3 资产情形下的一般复杂度水平。

表 3.4 不同算法实现的总体复杂度 Θ 对比

资产数	$\varepsilon = 1/8$		$\varepsilon = 1/16$		$\varepsilon = 1/4$	
	原方法	本文	原方法	本文	原方法	本文
2	33.82	21.05	35.42	22.65	32.22	19.45
3	36.76	25.32	38.36	26.93	35.16	23.72
4	38.17	24.30	39.77	25.91	36.57	22.70
5	38.94	24.27	40.55	25.87	37.34	22.66
6	39.56	24.61	41.16	26.22	37.96	23.01
减少幅度	36.13%		34.64%		36.94%	

3 资产的 Θ 中位数：23.94。

表 3.5 不同算法实现的具体电路复杂度对比 ($\varepsilon = 1/8$)

资产数	N^q		N^d		N^{CNOT}	
	原方法	本文	原方法	本文	原方法	本文
2	19.77	11.80	2.148×10^9	8.016×10^4	1.123×10^9	4.202×10^4
3	21.00	13.87	1.782×10^8	2.523×10^7	9.381×10^7	1.328×10^7
4	21.88	13.23	6.274×10^8	6.454×10^5	3.304×10^8	3.399×10^5
5	22.37	13.21	9.526×10^8	7.062×10^5	5.016×10^8	3.719×10^5
6	22.75	13.42	9.558×10^8	6.737×10^5	5.033×10^8	3.549×10^5
减少幅度	39.16%		97.12%		97.12%	

3 资产的中位数： $N^q = 13$, $N^d = 4.048 \times 10^5$, $N^{\text{CNOT}} = 2.132 \times 10^5$ 。

图 3.8 给出了与混合 HHL 算法和 Qiskit HHL 实现相比的精度提升。图 3.8(a) 设定了固定的量子比特数，显示本文相比 Qiskit HHL 实现平均提升了 1.52 倍的精度，相比混合 HHL 算法平均提升了 1.46 倍。对于有限的可用量子比特，本文降低了求解线性系统的难度，并确定了 HHL 算法更合理的参数设置，从而能够解决更复杂的问题。在 5 资产投资组合优化的情况下，图 3.8 (b) 显示本文相比 Qiskit HHL 实现平均提升了 1.28 倍的精度，相比混合 HHL 算法提升了 1.39 倍。特别地，拥有 4 量子比特 QPE 电路时，本文方法的精度 ($\Delta = 0.96$) 优于所有其他方法，即使其他方法的 QPE 量子比特数来到了 10 个。总之，通过利用布莱克模型的特征和历史金融信息，本文方法在精度和复杂度之间取得了更好的权衡。我们进一步进行了消融实验，以定量评估约束缩放系数和特征值估计的优势。这里，“本文（不进行约束缩放）”意味着我们使用原始矩阵训练特征值估计模型。对于“本文（不进行特征值估计）”的设计，我们采用与 Qiskit HHL 相同的方案，即利用 ExactReciprocal 对象。图 3.8 (a) 表明缩放因子贡献最大，在 5 量子比特 QPE 模

块的约束下,能提升精度从 1.74~1.96 倍;对于 5 资产投资组合优化,能提升精度 1.10~1.96 倍。这种提升主要得益于我们的搜索算法能够找到有效的约束缩放系数,从而显著降低线性系统的复杂度。而在不进行约束缩放的情况下,本文方法的表现略低于混合 HHL 方法和 Qiskit HHL 实现。这是因为巨大的条件数使得特征值更加难以预测,可能会产生极大的偏差,导致特征值预测模型效果不佳甚至适得其反。然而,混合 HHL 方法和 Qiskit HHL 实现不依赖条件数来估计特征值。具体而言,混合 HHL 算法通过矩阵的迹对矩阵进行标准化,而 Qiskit HHL 实现用带有符号位的 `ExactReciprocal` 对象,其中的归一化常数取决于 QPE 模块的量子比特数。特征值估计带来的增益在固定量子比特数和固定资产数下分别为 1.21~1.54 倍和 1.05~1.37 倍。通过利用先验知识,本文方法能够更精确地捕捉最小最大特征值,从而实现高精度。图 3.8 (b) 还表明,约束缩放技术对于小规模 QPE 下的量子结果能够实现更多的精度提升,这符合式 (3.40) 的趋势:该式表明解向量的误差上界与矩阵条件数 κ 正相关。由于约束缩放技术大幅降低了 κ ,因此在 QPE 量子比特数 n_p 较少(即精度资源受限)的情况下,相比于未缩放的高条件数矩阵,能够更显著地降低误差界限,从而实现精度的提升。




图 3.8 本文方法与 Qiskit HHL 实现^[1]和混合 HHL 算法^[2]的精度对比

3.7.4 关于约束缩放系数鲁棒性的评估

如第 3.4 节所述,约束缩放系数用于降低矩阵的条件数。本小节详细评估了静态约束缩放系数的鲁棒性。

我们在数据集中选择了一系列投资组合,搜索了各个组合的最佳约束缩放

系数,得到如图 3.9 (a) 所示的分布。可以观察到,大多数最佳缩放系数高度集中在一个较小的区域内。这种分布特征表明,不同投资组合的最优缩放参数具有高度的一致性,因此选取该区域的质心或中心点作为固定的静态参数,能够良好地适配绝大多数情况。以 AMEX 为例,考察最佳约束缩放系数集中区域的边界点, s_1 的范围为 $9.09 \times 10^{-2} \sim 0.634$, s_2 的范围为 $3.78 \times 10^{-4} \sim 2.21 \times 10^{-3}$ 。本文的搜索方法,可得到接近此区域中心的点。




图 3.9 关于静态约束缩放系数有效性的评估

如图 3.9 (b) 所示,我们还比较了使用边界点和最佳约束缩放系数所得到的条件数。即使选择边界点,条件数仍然可以大幅度减少(原有条件数可达 10^5 , 边界点将条件数降低为 ~ 10)。同样可以发现,当资产数增加,使用静态约束缩放系数(本文)和使用最佳约束缩放系数的差距在逐渐缩小,从 8.56 倍(2 个资产)降低至 1.23 倍(6 个资产),这进一步说明了静态约束缩放系数在大数据量下的有效性。最终,约束缩放系数将条件数降低了至少 98.59%。

3.7.5 关于特征值估计准确性的评估

在本节中,我们评估特征值预测器的精确度,并研究其如何影响解决投资组合优化的准确性。

首先,我们收集了 1500 个投资组合的特征值估计值,范围从 2 资产问题到 6 资产问题。然后,我们计算与真实特征值相比的相对误差,如图 3.10 (a) 的箱线图所示。总体而言,大多数预测值的相对误差在 50% 以内。某些样本的相对误差超过 100%,当资产数量为 2 时甚至超过 300%,这是因为一些特征值接近于零,

具有很高的浮点误差。图 3.10 (b) 描绘了使用真实特征值和预测特征值的精度差距，计算方式为 $(1 - \text{使用预测值的}\Delta / \text{使用真实值的}\Delta) \times 100\%$ 。在资产数为 2 的情况下，最大差距为 7.21%，这仍然是可接受的精度 ($\Delta = 0.901$)。特别是当资产数量为 5 时，由于精确的预测模型，这种差距几乎消失了。




图 3.10 特征值估计值的误差分析

我们还描绘了真实特征值的分布，如图 3.11 所示。我们观察到，当资产数量为 2 时， $|\lambda|_{\min}$ 集中在区间 $(0, 0.0001]$ 内。对于如此微小的数值，即使极小的绝对预测偏差也会导致显著的相对误差。相比之下， $|\lambda|_{\max}$ 的数值较大，相对误差受绝对偏差的影响较小，因此在图 3.10 (a) 中其相对误差远低于 $|\lambda|_{\min}$ 。




图 3.11 $|\lambda|_{\min}$ 和 $|\lambda|_{\max}$ 真实值的分布

3.8 本章总结

本章针对量子计算在解决投资组合优化时面临的扩展性差和精度低的问题，提出了一种面向特定领域的量子线性求解框架。首先，通过布莱克模型对问题进行线性建模，并引入约束缩放技术，利用下山单纯形算法搜索最优系数，有效降低了矩阵条件数。其次，结合特征值先验知识优化 HHL 电路设计，并构建

了基于支持向量回归的特征值估计模型。在真实股市数据上的实验表明，该框架在大幅降低量子电路复杂度的同时，显著提升了求解精度，验证了其在金融计算场景下的有效性。

第4章 基于量子夏普利值估算的风险归因应用

4.1 概述

在第3章中,本文针对投资组合优化的布莱克模型,构建了基于量子线性求解器的框架,并通过约束缩放技术和特征值估计模型,有效降低了量子电路复杂度、提升了量子算法计算精度,从而在量子计算机上获得了收益与风险平衡下的资产权重向量。然而,投资者不仅需要知道自身资产的配置,而且需要洞察投资组合风险的来源。由于金融资产本身的独有特性^[73]以及资产间复杂的非线性关联性^[74],资产的投资权重并不单纯等价于其风险贡献——一资金占比很小的资产,可能因为高波动性,成为整个投资组合风险的主导因素。举例来说,在股票与债券各占50%的投资组合中,股票资产因其高波动特征往往贡献了超过90%的组合总风险。

风险归因旨在将投资组合的整体风险分解为各个组成部分(如单一资产或风险因子)的边际贡献,从而量化每个部分对总风险的影响程度。在各类归因方法中,基于合作博弈论的夏普利值因满足有效性、对称性等公理化标准^[75],能够公平地分配由于资产间非线性相关所产生的“分散化效应”,被视为解决风险分配问题的理论基准。

现有在经典计算机上运行的夏普利值计算方法在算力上面临着严峻的挑战:依据夏普利值的定义,计算一个包含 n 个资产的投资组合,在数学上需要遍历 2^n 个可能的子组合,并计算每个子组合的边际风险贡献。尽管有基于蒙特卡洛等方法的采样近似算法^[76-78]在一定程度上缓解了维数灾难,但在追求高精度和实时性的场景下,大规模采样带来的计算成本依然高昂^[79,80]。量子计算具有高并行性、低功耗的潜在优势,为突破这一瓶颈提供了新的契机。利用量子叠加态,算法可以在同时编码所有可能的子组合状态,从而实现对夏普利值的快速估算。然而,要达成量子算法在风险归因场景中的有效适配,还需要解决金融属性与量子算法假设之间的内生冲突。具体而言,金融风险度量通常满足次可加性^[81],即多标的投资组合相较于单只标的风险更低;而由于量子态特征,量子夏普利值估计需要特征函数满足超可加性^[82],即合作增加收益。直接应用会导致物理意义的混淆和计算结果的失败。

针对上述量子算法与金融风险理论融合的挑战, 本文提出了基于量子夏普利值计算的风险归因。首先, 本文深入分析了风险价值 (value and risk, VaR) 与预期短缺 (expected shortfall, ES) 在数学性质上的差异, 针对 VaR 缺乏次可加性可能导致的归因逻辑失效问题, 确定了以 ES 作为核心风险度量指标。基于 ES 这一一致性风险度量, 本文构建了合作博弈模型。针对风险度量的次可加性与量子算法要求的超可加性之间的冲突, 本文创新性地设计了基于“风险节省”的对偶博弈模型, 将“风险成本分摊”博弈转化为“风险节省分配”博弈, 成功适配了量子算法的输入规范。通过真是市场的历史数据验证, 该方法不仅能以较高的精度还原经典夏普利值, 还能有效识别投资组合中的隐形风险热点, 为主动风险管理提供了强有力的量化工具。

4.2 基于夏普利值的风险归因模型

4.2.1 风险度量指标的选择

风险度量的核心功能是将投资组合未来的随机损益映射为一个具体的实数 (风险资本)。“一致性风险度量理论”要求: 对于所有风险随机变量的全集 $\mathcal{G}$, 一个合理的风险度量函数 ρ 必须满足变换不变性、正齐次性、单调性、次可加性四条公理^[83]。

- **变换不变性:** 对于任意确定性现金 c 和风险随机变量 $X \in \mathcal{G}$, 有 $\rho(X + c) = \rho(X) - c$; 这意味着增加无风险资产 (现金) 将等额降低风险。
- **正齐次性:** 对于任意常数 $\lambda > 0$ 和风险随机变量 $X \in \mathcal{G}$, 有 $\rho(\lambda X) = \lambda \rho(X)$; 即持仓规模放大 λ 倍, 风险也应放大相同倍数。
- **单调性:** 如果风险随机变量 $X \in \mathcal{G}$ 在任何状态下的收益都优于 $Y \in \mathcal{G}$ (即 $X \geq Y$), 则 $\rho(X) \leq \rho(Y)$ 。
- **次可加性:** 这是风险归因中最关键的性质, 对于任意两个风险随机变量 $X, Y \in \mathcal{G}$, 必须满足 $\rho(X + Y) \leq \rho(X) + \rho(Y)$; 这一公理是现代投资组合理论中“分散投资”的数学体现; 如果违背此公理, 意味着分散投资的风险反而大于单独投资之和, 这将导致归因结果出现逻辑悖论。

VaR 定义为在给定置信水平 α (一般取 $\alpha = 95\%$) 下, 资产在未来特定持有期内的最大可能损失。数学上, 设 L 为资产 (或投资组合) 在持有期内的随机损

失，则 VaR 是损失分布的 α 分位数：

$$\text{VaR}_\alpha(L) = \inf\{x \mid P(L > x) < 1 - \alpha\} \quad (4.1)$$

尽管 VaR 概念直观，但它并不满足次可加性，这可以通过二元期权、独立同分布变量等诸多反例证明^[83]。本文采用 ES 作为核心风险度量。ES 定义为超过 VaR 阈值的所有损失的期望：

$$\text{ES}_\alpha(L) = \mathbb{E}[L \mid L \geq \text{VaR}_\alpha(L)] \quad (4.2)$$

其积分形式定义为

$$\text{ES}_\alpha(L) = \frac{1}{1 - \alpha} \int_\alpha^1 \text{VaR}_\gamma(L) d\gamma \quad (4.3)$$

可以看到，ES 本质上是将随机损失映射为实数的泛函。在后续关于投资组合的讨论中，若投资组合由资产集合 S 组成，其总损失记为 $L_S = \sum_{j \in S} w_j X_j$ （其中 X_j 为各资产损失， w_j 为权重），则该组合的风险度量可记为 $\text{ES}(S)$ ；由于置信水平 α 通常是预先设定的常数，为了符号简洁，后续推导中将省略下标 α 。

如图 4.1 所示，VaR 仅考虑特定置信水平而丢失了尾部损失（红色虚线右侧部分），ES 则考虑了尾部损失的严重程度，修正了 VaR 在风险度量上的盲区。由于 ES 考虑了投资组合损失大于 VaR 的部分，因此在相同置信水平下 ES 必然不低于 VaR，所以一般认为 ES 比 VaR 更保守^[84,85]。




图 4.1 VaR 与 ES 值的对比

可以证明，ES 符合次可加性以及其他三项公理^[86]，是合理的一致性风险度

量。本文采用 ES 作为风险度量指标，并在后续利用其次可加性，完成合作博弈建模以及量子算法适配。

4.2.2 基于合作博弈的风险归因建模

合作博弈论的核心研究对象是一组能够通过结成**联盟**来改善自身收益或分摊共同成本的**玩家**。在数学上，一个合作博弈可由二元组 (N, V) 唯一确定：其中， N 为所有参与博弈的玩家的集合（令 n 为参加博弈的玩家人数， $n = |N|$ ）， $v: 2^n \rightarrow \mathbb{R}$ 为特征函数，用于定量描述任意联盟所代表的集合 $S \subseteq N$ 所能产生的总价值或成本。在这一框架下，核心问题始终围绕着“分配”展开，即如何以一种既符合数学逻辑又满足公平原则的方式，分配每个玩家对总收益或成本 $V(N)$ 的贡献。夏普利值为解决合作博弈的分配问题提供了思路^[75]。本质上讲，夏普利值并非简单的算术平均，而是基于**边际贡献**的加权平均，它考察的是一个玩家在所有可能的联盟中，对现有联盟所带来的增量影响。一般对夏普利值的定义如下：

$$\Phi_i = \sum_{S \subseteq N \setminus \{i\}} \gamma(n, s) [V(S \cup \{i\}) - V(S)] \quad (4.4)$$

其中， $V(S \cup \{i\}) - V(S)$ 就是第 i 个玩家对联盟 S 的边际贡献，而 Φ_i 就是第 i 个玩家的夏普利值。 $\gamma(n, s)$ 是边际收益的权重，记 $s = |S|$ ，有：

$$\gamma(n, s) = \frac{(n - s - 1)!s!}{n!} \quad (4.5)$$

通常来说，“计算夏普利值”指的是指定玩家 i 并计算 Φ_i ，而不是计算 n 个玩家的所有夏普利值，本文也将遵循这一约定。可以发现，依据夏普利值的定义，计算 Φ_i 需要枚举 N 的所有子集，时间复杂度为 $O(2^n)$ 。

上述合作博弈思想与投资组合的风险归因存在深层的同构性。由于各资产的自身特性以及资产间的非线性关联^[73,74]，各个资产风险不等于组合总风险按投资权重的等比例分配。一般来说，投资组合通过分散投资，可降低总风险；这种资产间通过组合进行相互作用产生的“风险减免”效果，与合作博弈中联盟成员协作产生的“协同盈余”在逻辑上是一致的。基于此，我们将风险归因建模为一个“风险分摊”的合作博弈，具体映射关系如下：

- 将投资组合中的各个资产视为参与博弈的玩家，
- 投资组合的任意资产子组合对应合作博弈中的联盟，

- 风险度量 ES 即为合作博弈的特征函数。

定义 4.1 基于上述模型，本文定义投资组合中第 i 个资产的风险归因指标为**夏普利风险贡献** (shapley risk contribution, SRC)，记为 Φ_i^{SRC} ：

$$\Phi_i^{\text{SRC}} = \sum_{S \subseteq N \setminus \{i\}} \underbrace{\gamma(n, s)}_{\text{组合权重}} \underbrace{[\text{ES}(S \cup \{i\}) - \text{ES}(S)]}_{\text{边际风险增量}} \quad (4.6)$$

可以从两个部分解读：

- 边际风险增量代表了资产 i 加入现有投资组合 S 后导致组合整体风险的变化，当资产 i 与高度正相关则该项为正且数值较大，当资产 i 与组合 S 负相关（对冲作用）则该项可能为负，体现资产的避险价值；
- 组合权重本质上是该投资组合 S 在随机排列中出现的概率，体现了总体平等性、平均加权性、平等贡献性^[87]。

为了更加直观地展示夏普利风险贡献在量化资产风险归因时的合理性，下面通过一个简化的数值案例，对比了夏普利值方法与按投资权重分配的方法。如图 4.2 (a) 所示，我们通过随机数据模拟了股票、债券以及两者等权投资组合的净值曲线。就波动来看，股票最大、债券最小，通过两者的等权组合，得到了兼具收益和回撤风险的投资组合。图 4.2 (b) 是与图 4.2 (a) 资产走势对应的风险度量 ES。对于单个资产，显然股票的风险相较于债券大得多。对于组合来说 ($\text{ES}(\text{组合}) = 16.3$)，其走势基本与股票一致，特别是在股票大幅回撤时，债券收益在缓慢增长，而组合的净值仍然大幅回撤。若按照组合的资产比例分配风险，显然与组合实际的净值走向不符；而通过夏普利风险贡献，我们可以量化出投资组合中具体拉高和对冲风险的资产——股票的夏普利风险贡献 ($\Phi_{\text{股票}}^{\text{SRC}} = 15.7$) 大幅超出债券 ($\Phi_{\text{债券}}^{\text{SRC}} = 0.6$)，两者总共贡献了 $\text{ES}(\text{组合}) = \Phi_{\text{股票}}^{\text{SRC}} + \Phi_{\text{债券}}^{\text{SRC}} = 16.3$ 的风险。




图 4.2 朴素等权分配和夏普利值对比

4.3 量子夏普利值估计算法

Burge 等人^[88]提出了在合作博弈的场景下计算夏普利值的量子算法。相较于原有工作,本节将详细推导该算法的量子态演化过程,并对其正确性进行严格的数学证明,为后续构建适用于金融风险归因的计算框架奠定理论基础。

复杂度

4.3.1 预先约定和说明

这里约定三个量子寄存器,初始量子态为:

$$|\psi_0\rangle = |0\rangle^{\otimes n_l} |0\rangle^{\otimes n_p} |0\rangle \quad (4.7)$$

- 区间寄存器 Q_l : 有 n_l 个量子比特,比特数认为指定,用于存放近似 $\beta(n, s)$ 的区间。
- 玩家寄存器 Q_p : 有 n_p 个量子比特,表示 n_p 个玩家,可通过叠加态表示 2^{n_p} 个联盟;对于合作博弈 (N, V) , $n_p = n - 1$,因为计算 Φ_i 需要枚举 $N \setminus \{i\}$ 的所有子集。
- 贡献寄存器 Q_a : 存储一个辅助比特,用于存储通过 U_W 转换而来的边际贡献。

对于合作博弈 (N, V) ,量子算法只考虑超可加性的博弈,即

$$\forall A, B \subseteq N, A \cap B = \emptyset \quad V(A \cup B) \geq V(A) + V(B) \quad (4.8)$$

可以发现,超可加性与风险度量 ES 的次可加性完全矛盾。本节暂时在超可

加性博弈的范围内展开，并将在第4.4节提出创新性的对偶博弈模型解决这一矛盾。

4.3.2 夏普利权重的量子积分近似

在量子态上计算阶乘形式的夏普利值权重 $\gamma(n, s)$ 并不容易，我们首先将权重与定积分等价，再利用定积分的几何意义求其近似值。

定义 4.2 定义定积分

$$\beta(n, s) = \int_0^1 x^s (1-x)^{n-s-1} dx, \quad s = 0, 1, \dots, n-1 \quad (4.9)$$

下面将证明 $\gamma(n, s)$ 和 $\beta(n, s)$ 的等价性。

引理 4.1 对于 $\beta(n, s)$ ，有如下递推关系：

$$\beta(n, s) = \frac{s}{n-s} \beta(n, s-1) \quad (4.10)$$

证明 根据分步积分规则， $\int u dv = uv - \int v du$ ，令 $u = x^s$ 、 $dv = (1-x)^{n-s-1} dx$ ，有

$$\begin{aligned} \beta(n, s) &= \frac{x^s (1-x)^{n-s}}{n-s} \Big|_0^1 + \int_0^1 \frac{s}{n-s} (1-x)^{n-s} x^{s-1} dx \\ &= \frac{s}{n-s} \int_0^1 x^{s-1} (1-x)^{n-s} dx \\ &= \frac{s}{n-s} \beta(n, s-1) \end{aligned} \quad (4.11)$$

□

定理 4.1 $\beta(n, s)$ 所表示的积分与夏普利值的权重 $\gamma(n, s)$ ，对于 $s = 0, 1, \dots, n-1$ 严格相等。

证明 下面用数学归纳法证明。

显然，当 $s = 0$ 时， $\beta(n, 0) = \gamma(n, 0)$ ：


$$\begin{aligned}\beta(n, 0) &= \int_0^1 (1-x)^{n-1} dx = -\frac{1}{n}(1-x)^n \Big|_0^1 = \frac{1}{n} \\ \gamma(n, 0) &= \frac{(n-1)!0!}{n!} = \frac{1}{n}\end{aligned}\tag{4.12}$$

假设当 $s = k$ 时有 $\beta(n, k) = \gamma(n, k)$, 那么当 $s = k+1$ 时, 结合引理 4.1, 可得

$$\begin{aligned}\beta(n, k+1) &= \frac{k+1}{n-k-1}\beta(n, k) \\ &= \frac{k+1}{n-k-1}\gamma(n, k) \\ &= \frac{k+1}{n-k-1} \frac{k!(n-k-1)!}{n!} \\ &= \frac{(k+1)!(n-k-2)!}{n!} \\ &= \frac{(k+1)![n-(k+1)-1]!}{n!} \\ &= \gamma(n, k+1)\end{aligned}\tag{4.13}$$

□

基于定理 4.1, 我们将“利用量子态计算权重 $\gamma(n, s)$ ”这一问题转化为“利用量子态计算定积分 $\beta(n, s)$ ”。在算法中, 可利用该定积分的几何意义^[89] 计算其近似值。如图 4.3 所示, 定积分的真值对应于函数曲线下的面积, 而这一面积可以通过一系列矩形的面积之和(黎曼和)进行近似。其中, 每个矩形的宽度对应于积分区间的一次离散划分, 高度则由区间内选定的采样点(红色圆点)处的函数值决定。由于量子态本身是离散的, 这种将连续积分转化为离散采样求和的处理方式, 为后续利用量子位概率幅编码定积分提供了理论基础。下面将详细阐述区间划分的具体数学方法以及采样点的选取逻辑。

图 4.3 利用定积分的几何意义计算 $\beta(n, s)$ 近似值

定义 4.3 定义区间 $[0, 1]$ 中的 $2^{n_l} + 1$ 个点的点集

$$P_{n_l} = \{p_{n_l}(k)\}_{k=0}^{2^{n_l}} \quad (4.14)$$

其中

$$p_{n_l}(k) = \sin^2\left(\frac{\pi k}{2^{n_l}+1}\right) \quad (4.15)$$

引理 4.2 $p_{n_l}(k)$ 在 $k \in [0, 2^{n_l}]$ 区间内是单调递增的。

证明 令 $\theta_k = \frac{\pi k}{2^{n_l}+1}$, 其范围是 $0 \leq \theta_k \leq \frac{\pi}{2}$ 。由于 $\sin \theta$ 在 $\theta \in [0, \frac{\pi}{2}]$ 区间内单调递增, 故 $p_{n_l}(k)$ 在 $k \in [0, 2^{n_l}]$ 上也是单调递增的, 证毕。 $\square$

定义 4.4 利用 P_{n_l} 可以定义 $[0, 1]$ 中的 2^{n_l} 个区间 $[p_{n_l}(k), p_{n_l}(k+1)]$ 。令区间长度为

$$\Delta x_{n_l}(k) = p_{n_l}(k+1) - p_{n_l}(k) \quad (4.16)$$

定理 4.2 $\{\sqrt{\Delta x_{n_l}(k)}\}_{k=0}^{2^{n_l}-1}$ 可作为 n_l 个量子比特系统的量子态振幅。

证明 下面从概率的角度证明。

单个状态的概率 $\left| \sqrt{\Delta x_{n_l}(k)} \right|^2 = \Delta x_{n_l}(k)$ 在区间 $[0, 1]$ 内:

- 基于引理 4.2, 必然有 $p_{n_l}(k+1) \geq p_{n_l}(k)$, 故 $\Delta x_{n_l}(k) \geq 0$;
- 基于引理 4.2, 必然有 $\max_k p_{n_l}(k) = p_{n_l}(\pi/2) = 1$, $\min_k p_{n_l}(k) = p_{n_l}(0) = 0$, 所以 $\Delta x_{n_l}(k) \leq \max_k p_{n_l}(k) - \min_k p_{n_l}(k) = 1$, 即 $\Delta x_{n_l}(k) \leq 1$ 。

各个状态的概率和为 1, 满足式 (2.9):

$$\begin{aligned}
 \sum_{k=0}^{2^{n_l}-1} \left| \sqrt{\Delta x_{n_l}(k)} \right|^2 &= \sum_{k=0}^{2^{n_l}-1} \Delta x_{n_l}(k) \\
 &= \sum_{k=0}^{2^{n_l}-1} p_{n_l}(k+1) - p_{n_l}(k) \\
 &= p_{n_l}(2^{n_l}) - p_{n_l}(0) \\
 &= \sin^2 \frac{\pi}{2} - \sin^2 0 \\
 &= 1
 \end{aligned} \tag{4.17}$$

将 $\left\{ \sqrt{\Delta x_{n_l}(k)} \right\}_{k=0}^{2^{n_l}-1}$ 作为表达各个状态概率的振幅合法, 证毕。 $\square$

定理 4.3 采样点 $p'_{n_l}(k) = p_{n_l+1}(2k+1)$ 是区间 $[p_{n_l}(k), p_{n_l}(k+1)]$ 的内点。

证明 已知

$$\begin{aligned}
 p_{n_l}(k) &= \sin^2 \left(\frac{\pi}{2} \cdot \frac{k}{2^{n_l}} \right) \\
 p'_{n_l}(k) &= p_{n_l+1}(2k+1) = \sin^2 \left[\frac{\pi}{2} \cdot \left(\frac{k}{2^{n_l}} + \frac{1}{2^{n_l+1}} \right) \right] \\
 p_{n_l}(k+1) &= \sin^2 \left[\frac{\pi}{2} \left(\frac{k}{2^{n_l}} + \frac{1}{2^{n_l}} \right) \right]
 \end{aligned} \tag{4.18}$$

可以发现, 在上述三式中, $\sin^2(\cdot)$ 括号内的值位于区间 $[0, \pi/2]$, 且逐渐递增。由于 $y = \sin^2 x$ 在 $x \in [0, \pi/2]$ 单调递增, 故 $p'_{n_l}(k) \in [p_{n_l}(k), p_{n_l}(k+1)]$, 证毕。 $\square$

基于定义 4.4 和定理 4.3, 我们将 $[0, 1]$ 分割为 2^{n_l} 个区间, 每段区间范围是

$[p_{n_l}(k), p_{n_l}(k+1)]$ ，并选择 $p'_{n_l}(k)$ 为区间采样点。至此，我们完成了积分近似的数学构建。通过正弦变换生成的非均匀区间 $\Delta x_{n_l}(k)$ 和采样点 $p'_{n_l}(k)$ ，不仅在几何上构成了对积分面积的逼近（图 4.3），而且在物理上适配了量子态的概率幅分布（定理 4.2）。这种离散化方案巧妙地将复杂的权重积分转化为量子电路可直接处理的离散求和形式。

算法分别通过概率制备和受控旋转构造近似计算 $\beta(n, s)$ 的区间和采样点对应的被积函数值。首先，基于定理 4.2，我们首先可以通过等距变换^[51]等概率制备方法，得到如下量子态：

$$|\psi_1\rangle = \sum_{k=0}^{2^{n_l}-1} \sqrt{\Delta x_{n_l}(k)} |k\rangle |0\rangle^{\otimes n_p} |0\rangle \quad (4.19)$$

可以发现，通过概率制备得到的式 (4.19) 已有了用于近似 $\beta(n, s)$ 的 2^{n_l} 个区间长度。随后，用于制备区间采样点 $p'_{n_l}(k)$ 对应被积函数值的量子电路如图 4.4 所示。




图 4.4 制备采样点 $p'_{n_l}(k)$ 对应被积函数值的量子电路

定理 4.4 记图 4.4 所示电路为 R ，该电路满足

$$R|k\rangle|0\rangle = |k\rangle(\sqrt{1-p'_{n_l}(k)}|0\rangle + \sqrt{p'_{n_l}(k)}|1\rangle) \quad (4.20)$$

证明 如图 4.4 所示，每个受控 R_Y 门的旋转角度依次为 $\pi/2, \pi/2^2, \dots, \pi/2^{n_l+1}$ ，若 $k = \overline{k_0 k_1 \dots k_{n_l-1}}$ 中某一位 $k_i = 1$ ，则旋转对应的角度，否则不做任何操作。因此 R 可以抽象成一系列普通 R_Y 门，旋转角度依次为 $k_{n_l-1} \cdot \pi/2, k_{n_l-1} \cdot \pi/2^2, \dots, k_0 \cdot \pi/2^{n_l}, \pi/2^{n_l+1}$ ，将所有旋转角度求和，等效为一个 R_Y 门：

$$\begin{aligned}
R &= R_Y \left(\frac{\pi}{2^{n_l+1}} + \sum_{i=0}^{n_l-1} \frac{\pi}{2^{n_l-i}} k_i \right) \\
&= R_Y \left(\frac{\pi}{2^{n_l+1}} + \frac{\pi}{2^{n_l}} \sum_{i=0}^{n_l-1} 2^i k_i \right) \\
&= R_Y \left(\frac{\pi}{2^{n_l+1}} + \frac{\pi}{2} k \right) \\
&= R_Y \left[\pi \cdot \left(\frac{k}{2^{n_l}} + \frac{1}{2^{n_l+1}} \right) \right]
\end{aligned} \tag{4.21}$$

将上式代入，得

$$\begin{aligned}
R|k\rangle|0\rangle &= |k\rangle R_Y \left[\pi \cdot \left(\frac{k}{2^{n_l}} + \frac{1}{2^{n_l+1}} \right) \right] |0\rangle \\
&= |k\rangle \left\{ \cos \left[\frac{\pi}{2} \cdot \left(\frac{k}{2^{n_l}} + \frac{1}{2^{n_l+1}} \right) \right] |0\rangle + \sin \left[\frac{\pi}{2} \cdot \left(\frac{k}{2^{n_l}} + \frac{1}{2^{n_l+1}} \right) \right] |1\rangle \right\}
\end{aligned} \tag{4.22}$$

将 $p'_{n_l}(k)$ 代入上式，可得 $R|k\rangle|0\rangle = |k\rangle (\sqrt{1-p'_{n_l}(k)}|0\rangle + \sqrt{p'_{n_l}(k)}|1\rangle)$ ，证毕。 $\square$

4.3.3 边际贡献的量子编码

在计算指定玩家 i 的夏普利值 Φ_i 时，需要评估其对所有可能联盟 $S_h \subseteq N \setminus \{i\}$ 的边际贡献。设 n 为参与博弈的玩家总数（即资产数量， $n = |N|$ ），由于集合 $N \setminus \{i\}$ 的规模为 $n-1$ ，我们定义玩家寄存器 Q_p 包含 $n_p = n-1$ 个量子比特。我们用 n_p 位二进制串 $\overline{h_1 h_2 \cdots h_{i-1} h_{i+1} \cdots h_n}$ 表示联盟 S_h ，其中每个比特位 h_k ($k \neq i$) 对应一个玩家：若 $h_k = 1$ 则表示第 k 个玩家属于联盟 S_h ，否则不属于。利用量子叠加态，算法可以在 Q_p 寄存器中并行处理所有 2^{n_p} 种可能的联盟组合，从而规避了经典计算中对联盟数量的指数级遍历。

为了方便后续说明，下面基于 h 对边际贡献进行一系列定义。首先，出于符号简化需求，定义玩家 i 加入联盟 S_h 后产生的边际贡献为

$$W(h) = V(S_h \cup \{i\}) - V(S_h), \quad S_h \subseteq N \setminus \{i\} \tag{4.23}$$

基于 i 能产生最大的边际贡献，可定义一个不小于所有边际贡献的极大值：

$$W_{\max} \geq \max_{S_h \subseteq N \setminus \{i\}} W(h) \quad (4.24)$$

将所有边际贡献缩放到 $[0, 1]$ 区间内, 可得

$$\widehat{W}_h = \frac{W(h)}{W_{\max}} \quad (4.25)$$

用一个旋转门 U_W 实现边际贡献从经典数据转移为量子态的过程, 其本质是一个受控 R_Y 门:

$$U_W |h\rangle |0\rangle = |h\rangle \left(\sqrt{1 - \widehat{W}(h)} |0\rangle + \sqrt{\widehat{W}(h)} |1\rangle \right) \quad (4.26)$$

由于特征函数 V 满足如式 (4.8) 所述的超可加性, 边际贡献恒为正, 作用 U_W 后的量子态必然有意义。

4.3.4 算法整体演化与测量

首先按照式 (4.19) 制备处于叠加态的区间长度, 随后对 Q_p 中的所有量子比特施加图 4.4 中的旋转电路 R 。此时, 系统状态演化为:

$$|\psi_2\rangle = \sum_{k=0}^{2^{n_l}-1} \sqrt{\Delta x_{n_l}(k)} |k\rangle \left(\sqrt{1 - p'_{n_l}(k)} |0\rangle + \sqrt{p'_{n_l}(k)} |1\rangle \right)^{\otimes n_p} |0\rangle \quad (4.27)$$

令 H_s 为与 $|0\rangle^{\otimes n_p}$ 汉明距离为 s 的量子态集合。从汉明距离的角度看, 此时 Q_p 中的量子态具有特殊性质。具体来说, 对于 n_p 量子比特的 Q_p , 量子态可以写为

$$\sum_{s=0}^{n_p} \sqrt{[p'_{n_l}(k)]^s [1 - p'_{n_l}(k)]^{n_p-s}} \sum_{h \in H_s} |h\rangle \quad (4.28)$$

其中, h 中 1 的个数即为汉明距离 s 。因此在式 (4.28), h 为计算夏普利值时枚举的子集的二进制表示, s 等价于子集的大小。

用上述形式描述 $|\psi_2\rangle$, 并利用 k, s, h 的独立性交换求和符号, 可得:

$$|\psi_2\rangle = \sum_{s=0}^{n_p} \sum_{h \in H_s} \sum_{k=0}^{2^{n_l}-1} \sqrt{\Delta x_{n_l}(k) [p'_{n_l}(k)]^s [1 - p'_{n_l}(k)]^{n_p-s}} |k\rangle |h\rangle |0\rangle \quad (4.29)$$

接着作用 U_W 门, 将边际贡献编码进辅助比特 Q_a :

$$\begin{aligned}
|\psi_3\rangle = & \sum_{s=0}^{n_p} \sum_{h \in H_s} \sum_{k=0}^{2^{n_l}-1} \sqrt{\Delta x_{n_l}(k) [p'_{n_l}(k)]^s [1 - p'_{n_l}(k)]^{n_p-s}} \\
& \cdot |k\rangle |h\rangle \left(\sqrt{1 - \widehat{W}(h)} |0\rangle + \sqrt{\widehat{W}(h)} |1\rangle \right)
\end{aligned} \tag{4.30}$$

定理 4.5 当使用足够多的量子比特时，式 (4.30) 高亮部分的量子态构造能够收敛到真实的夏普利值权重，即

$$\lim_{n_l \rightarrow \infty} \sum_{k=0}^{2^{n_l}-1} \Delta x_{n_l}(k) (p'_{n_l}(k))^s (1 - p'_{n_l}(k))^{n_p-s} = \gamma(n, s) \tag{4.31}$$

证明 对于区间 $[p_{n_l}(k), p_{n_l}(k+1)]$ ，已知 $\Delta x_{n_l}(k)$ 为区间长度 (定义 4.4)、 $p'_{n_l}(k)$ 为区间内一点 (定理 4.3)。 $[0, 1]$ 内共有 2^{n_l} 个区间，因此根据定义 4.2，再结合定积分的几何意义，可得

$$\begin{aligned}
\beta(n, s) &= \int_0^1 x^s (1-x)^{n-s-1} dx \\
&= \lim_{n_l \rightarrow \infty} \sum_{k=0}^{2^{n_l}-1} \Delta x_{n_l}(k) (p'_{n_l}(k))^s (1 - p'_{n_l}(k))^{n-s-1}
\end{aligned} \tag{4.32}$$

将 $n = n_p + 1$ 代入上式，得

$$\beta(n, s) = \lim_{n_l \rightarrow \infty} \sum_{k=0}^{2^{n_l}-1} \Delta x_{n_l}(k) (p'_{n_l}(k))^s (1 - p'_{n_l}(k))^{n_p-s} \tag{4.33}$$

又根据定理 4.1 有 $\gamma(n, s) = \beta(n, s)$ ，证毕。 $\square$

利用定理 4.5 的结论，对 $|\psi_3\rangle$ 取偏迹：

$$\begin{aligned}
& \text{tr}_{Q_l, Q_p}(|\psi_3\rangle\langle\psi_3|) \\
&= \sum_{s=0}^{n_p} \sum_{h \in H_s} \sum_{k=0}^{2^{n_l}-1} \Delta x_{n_l}(k) [p'_{n_l}(k)]^s [1 - p'_{n_l}(k)]^{n_p-s} |\varphi_h\rangle\langle\varphi_h| \\
&\approx \sum_{s=0}^{n_p} \sum_{h \in H_s} \gamma(n, s) |\varphi_h\rangle\langle\varphi_h| \\
&= \sum_{s=0}^{n_p} \sum_{h \in H_s} \gamma(n, s) \begin{bmatrix} 1 - \widehat{W}(h) & \sqrt{\widehat{W}(h)(1 - \widehat{W}(h))} \\ \sqrt{\widehat{W}(h)(1 - \widehat{W}(h))} & \widehat{W}(h) \end{bmatrix}
\end{aligned} \tag{4.34}$$

其中 $|\varphi_h\rangle = \sqrt{1 - \widehat{W}(h)}|0\rangle + \sqrt{\widehat{W}(h)}|1\rangle$ 。观察式 (4.34) 可知，寄存器 Q_a 中的单个辅助量子比特处于 $|1\rangle$ 态的概率 $P(|1\rangle)$ 为：

$$\begin{aligned}
P(|1\rangle) &= \sum_{s=0}^{n_p} \sum_{h \in H_s} \gamma(n, s) \widehat{W}(h) \\
&= \sum_{s=0}^{n_p} \sum_{h \in H_s} \gamma(n, s) \frac{V(S_h \cup \{i\}) - V(S_h)}{W_{\max}}
\end{aligned} \tag{4.35}$$

式 (4.35) 两个求和符号的含义为：枚举子集大小 s ，再枚举子集大小为 s 的所有子集。因此，式 (4.35) 的枚举内容与式 (4.4) 关于夏普利值定义中直接枚举所有子集是等价的，即 $P(|1\rangle) = \Phi_i / W_{\max}$ 。由此可见，通过对辅助比特进行 QAE^[40-43]，即可获得 Φ_i 。

4.4 风险节省博弈模型

在第 4.3 节中，本文详细阐述了夏普利值计算的量子算法框架。然而，由于金融风险度量的内在属性与量子算法假设之间的数学性质冲突，难以量子算法直接应用于以 ES 为核心指标的金融风险归因场景。本节旨在解决这一核心矛盾。我们首先深入剖析金融风险的次可加性与量子算法的超可加性假设之间的内生冲突，随后提出一种基于风险节省（risk saving, RS）的对偶博弈模型。风险节省博弈模型通过对特征函数进行数学转换，将原本的“风险成本分摊”问题转化为“风险节省分配”问题，从而成功适配量子算法的输入规范，并最终推导出了将量子算法得到的风险节省贡献还原为真实风险归因值的解析关系。

4.4.1 次可加性与超可加性的根本矛盾

如第 4.2.1 小节所述，为了保证风险归因逻辑的自洽性，本文选择满足一致性风险度量标准的 ES 作为特征函数。需要明确的是，在一致性风险度量的公理化定义中，其操作对象是代表随机风险损失的随机变量^[83]，而非集合。在投资组合风险归因的语境下，我们将不同的资产视为博弈的玩家，则对于两个不相交的资产集合 A 和 B （即 $A \cap B = \emptyset$ ），ES 的次可加性可以表述为

$$\text{ES}(A \cup B) \leq \text{ES}(A) + \text{ES}(B) \quad (4.36)$$

这一不等式的金融含义是：通过资产组合的分散化投资，整体风险应该不超过各部分独立风险之和。然而，第 4.3 节介绍的量子夏普利值估算算法在设计边际贡献算子 U_W 时，暗含了对特征函数满足如式 (4.8) 所述的超可加性的特定假设。

可以发现，次可加性与超可加性的数学性质截然相反。若忽略该差异而直接将 ES 为特征函数的博弈模型应用于量子算法，则会导致数学逻辑层面的失配。在量子夏普利值估算算法中，计算边际贡献的核心步骤是将特征函数的值 V 编码为量子态的概率幅。这一过程利用式 (4.26) 的 U_W 门实现，其本质上可以看作 R_Y 门，旋转角度为 $2 \arcsin \sqrt{\widehat{W}(h)}$ 。由于 $\widehat{W}(h)$ 是边际贡献的缩放值，因此其与边际贡献同号。当资产发挥对冲作用时（如图 4.2 中的例子），边际贡献可以为负数，若试图直接编码这一负的边际贡献，数学上将面临对负数开平方的困境，导致变为复数。在实数域定义的量子逻辑门参数空间中，这是无定义的。

4.4.2 对偶转换策略

为了解决上述冲突，本文在此提出一种对偶转换策略，其核心思想是转换合作博弈的视角：将原本的“风险成本分摊”博弈转化为其对偶的“风险节省分配”博弈。

定义 4.5 设 N 为资产全集, 对于任意投资组合 $S \subseteq N$, 风险节省特征函数为

$$RS(S) = \left(\sum_{j \in S} ES(\{j\}) \right) - ES(S) \quad (4.37)$$

其中, 第一项 $\sum_{j \in S} ES(\{j\})$ 表示投资组合 S 中各个资产单独投资时的风险总和, 第二项 $ES(S)$ 则为投资组合的实际风险, 两者之差即为投资组合通过分散化投资所节省的风险额, 称为**风险节省**。

定理 4.6 风险节省特征函数 $RS(S)$ 满足超可加性。

证明 对于任意两个不相交的投资组合 $A, B \subseteq N$ (即 $A \cap B = \emptyset$), 考察投资组合 $A \cup B$ 的风险节省:

$$\begin{aligned} RS(A \cup B) &= \left[\sum_{j \in A \cup B} ES(\{j\}) \right] - ES(A \cup B) \\ &= \left[\sum_{j \in A} ES(\{j\}) + \sum_{j \in B} ES(\{j\}) \right] - ES(A \cup B) \end{aligned} \quad (4.38)$$

将表示 ES 具有次可加性的不等关系式 (4.36) 代入, 得

$$\begin{aligned} RS(A \cup B) &\geq \left[\sum_{j \in A} ES(\{j\}) + \sum_{j \in B} ES(\{j\}) \right] - [ES(A) + ES(B)] \\ &= \left[\sum_{j \in A} ES(\{j\}) - ES(A) \right] + \left[\sum_{j \in B} ES(\{j\}) - ES(B) \right] \\ &= RS(A) + RS(B) \end{aligned} \quad (4.39)$$

即 $RS(A \cup B) \geq RS(A) + RS(B)$, 证毕。 $\square$

定理 4.6 从数学上严格保证了 RS 具有超可加性。这意味着, 随着投资组合规模的扩大, 风险节省只会增加不会减少, 或至少保持不变。这一性质契合了量子算法对输入数据的要求, 使得我们可以将 RS 作为有效的特征函数编码进量子态, 最终得到对应的夏普利值, 我们将此利用 RS 作为特征函数的夏普利值记为 Φ_i^{RS} :

$$\Phi_i^{\text{RS}} = \sum_{S \subseteq N \setminus \{i\}} \gamma(n, s) [\text{RS}(S \cup \{i\}) - \text{RS}(S)] \quad (4.40)$$

4.4.3 归因结果的还原机制

通过对偶模型，我们可以得到基于 RS 的夏普利值 Φ_i^{RS} 。然而，风险归因的最终目标是获取资产对原始风险 ES 的贡献，即 Φ_i^{SRC} 。因此，需要建立从 Φ_i^{RS} 到 Φ_i^{SRC} 的还原机制。

定理 4.7 将 ES 作为特征函数的夏普利值和将 RS 作为特征函数的夏普利值，存在如下映射关系：

$$\Phi_i^{\text{SRC}} = \text{ES}(\{i\}) - \Phi_i^{\text{RS}} \quad (4.41)$$

证明 首先计算在风险节省场景中，资产 i 的边际贡献：

$$\begin{aligned} & \text{RS}(S \cup \{i\}) - \text{RS}(S) \\ &= \left[\left(\sum_{j \in S \cup \{i\}} \text{ES}(\{j\}) \right) - \text{ES}(S \cup \{i\}) \right] - \left[\left(\sum_{j \in S} \text{ES}(\{j\}) \right) - \text{ES}(S) \right] \\ &= \left[\left(\sum_{j \in S} \text{ES}(\{j\}) \right) + \text{ES}(\{i\}) - \text{ES}(S \cup \{i\}) \right] \\ & \quad - \left[\left(\sum_{j \in S} \text{ES}(\{j\}) \right) - \text{ES}(S) \right] \\ &= \text{ES}(\{i\}) - [\text{ES}(S \cup \{i\}) - \text{ES}(S)] \end{aligned} \quad (4.42)$$

将式 (4.42) 代入式 (4.40)，得

$$\begin{aligned} \Phi_i^{\text{RS}} &= \sum_{S \subseteq N \setminus \{i\}} \gamma(n, s) \{ \text{ES}(\{i\}) - [\text{ES}(S \cup \{i\}) - \text{ES}(S)] \} \\ &= \underbrace{\sum_{S \subseteq N \setminus \{i\}} \gamma(n, s) \text{ES}(\{i\})}_{\text{第一部分}} - \\ & \quad \underbrace{\sum_{S \subseteq N \setminus \{i\}} \gamma(n, s) [\text{ES}(S \cup \{i\}) - \text{ES}(S)]}_{\text{第二部分}} \end{aligned} \quad (4.43)$$

由于集合大小为 s 的子集共有 C_{n-1}^s 个，每个子集的权重为 $\gamma(n, s)$ ，因此权重的和为

$$\begin{aligned}
 \sum_{S \subseteq N \setminus \{i\}} \gamma(n, s) &= \sum_{s=0}^{n-1} \binom{n-1}{s} \gamma(n, s) \\
 &= \sum_{s=0}^{n-1} \frac{(n-1)!}{s!(n-s-1)!} \frac{s!(n-s-1)!}{n!} \\
 &= \sum_{s=0}^{n-1} \frac{1}{n} \\
 &= 1
 \end{aligned} \tag{4.44}$$

所以，对于第一部分：

$$\sum_{S \subseteq N \setminus \{i\}} \gamma(n, s) \text{ES}(\{i\}) = \text{ES}(\{i\}) \sum_{S \subseteq N \setminus \{i\}} \gamma(n, s) = \text{ES}(\{i\}) \tag{4.45}$$

而对于第二部分，则完全符合式 (4.6) 对于 Φ_i^{SRC} 的定义。故 $\Phi_i^{\text{RS}} = \text{ES}(\{i\}) - \Phi_i^{\text{SRC}}$ ，与待证式 (4.41) 等价。□

从计算复杂度看，式 (4.41) 所表达的还原关系仅为 $O(1)$ 。这意味着，我们并未引入额外的计算负担，就成功解决了金融风险度量与量子算法的性质冲突问题。整个流程经过经典数据预处理计算独立 ES、转化得到投资组合 RS、量子算法计算夏普利值 Φ_i^{RS} ，利用还原公式得出归因值 Φ_i^{SRC} ——构成了一个闭环且高效的混合计算框架。

4.5 量子方案的实验验证

4.5.1 实验配置

投资组合的风险度量 在所有实验中，组合的各个资产配比都是等权的。投资组合使用 ES 进行风险度量，组合的 ES 值通过历史模拟法计算。具体来说，

量子算法的实现 计算夏普利值的量子算法的主体电路使用 Qiskit 构建，后续结果提取则采用了 Qiskit 状态向量 (Statevector 类)、多次采样 (在 Qiskit 中即为配置电路执行的 shots)、各类 QAE 等多种方式，其中 QAE 基于 Qiskit 生态的 qiskit-algorithms 实现。

后面写历史模拟法的计算过程

对比基准 本文令基于定义 4.1 进行穷举计算得到风险归因值为基准值。利用该基准值，可以得到其他计算方法相较于基准值的绝对误差和相对误差。

4.5.2 实验数据集构建

为了克服单一市场下资产的同质化，本文构建了一个包含 120 个资产的实验数据集。数据来源为全球市场的股票、ETF 等投资品。我们选取时间段为 2020 年 4 月至 2022 年 4 月的数据，在该时间窗口内，包含了流动性牛市以及美联储加息周期，权益类、固收类等不同类型资产具有极高的波动异质性：

- **高波动权益资产** 主要涵盖科技成长、半导体及数字经济概念股，样本包括英伟达、特斯拉等，此类资产在样本期内表现出显著的右偏分布与厚尾特征，代表了市场风险暴露的主要来源；
- **稳健蓝筹资产** 涵盖必选消费、医疗保健及科技龙头公司等防御性标的，样本包括可口可乐、强生、宝洁等，此类资产在样本期内波动率适中且具备抗周期性，能够在市场下行区间提供显著的防御缓冲；
- **避险与对冲资产** 引入了国债 20+ 年债券指数 ETF、金条价格 ETF 等；此类资产在选取时间段内，波动小，且收益稳步上升，可验证算法在负相关资产上的表现。

为了将上述定性描述转化为定量的实验分组，本文引入波动率这一指标来刻画资产风险维度的显著差异。波动率定义为资产对数收益率序列的年化标准差，其中对数收益率 $r_t = \ln(P_t) - \ln(P_{t-1})$ ， P_t 表示 t 时刻（以天为单位）的资产价格。依据波动率大小，我们将实验样本集中的所有资产按分位数划分为高、中、低三层资产池，具体统计特征如表 4.1 所示。从表中可以观察到，高风险资产虽然在特定区间内取得较高的年化收益，但其最大回撤高达 48.2%，显示出极端的尾部风险。相比之下，低风险资产通过引入国债、黄金等避险资产，有效将最大回撤控制在 7% 以内，体现了显著的对冲属性。

表 4.1 不同风险资产池的统计特征（2020 年 4 月至 2022 年 4 月）

风险分层	分位数范围	平均波动率	年化收益率	最大回撤
高风险资产池	前 30%	38.7%	56.3%	48.2%
中风险资产池	中间 40%	18.1%	34.1%	11.6%
低风险资产池	后 30%	10.1%	16.0%	6.8%

进一步地，为了捕捉各组资产的风险随时间的动态演变过程，图 4.5 展示了三类资产池的累积净值曲线（上图）以及 30 日滚动波动率（下图）。其中，滚动波动率定义为过去 30 个交易日收益率标准差的年化值，是衡量短期市场恐慌情绪与风险水平的重要指标。可以发现，三类资产池在收益特征与风险结构上呈现出鲜明的分化态势。高风险资产池在流动性充裕的宽松期内净值大幅攀升，但随着美联储启动加息周期，流动性收紧导致其净值出现剧烈回撤，且 30 日滚动波动率在该时段内持续维持高位，反映出其强烈的顺周期性与尾部风险敏感性。中风险资产池净值走势较为平稳，在加息冲击下虽有所承压，但回撤幅度远小于高风险组，波动率亦仅出现温和抬升，体现出显著的抗周期缓冲能力。低风险资产池则独具特色净值始终稳步上行，其波动率全程处于低位，且在特定区间上与高风险资产呈现出负相关走势。




图 4.5 三类资产池的累积净值与动态风险特征

4.5.3 理论框架正确性的数值验证

第 4.4 节提出了基于风险节省的合作博弈模型，本文在数学上严格证明了：通过还原公式，可无损地将模型输出结果转化为夏普利风险归因值 Φ_i^{SRC} （定理 4.7）。本小节旨在在数值层面进一步验证该理论框架的正确性，这是保证量子算法输入合法，且输出具有金融意义的前提。

表 4.2 超可加性验证结果统计

测试指标	统计数值	金融含义
差值最小值	0.009668	同类资产投资带来的风险减少下限
差值平均值	0.037385	投资组合整体的风险分散化均值
差值最大值	0.095162	强互补资产间的风险对冲效果
违例次数（差值 $< -10^{-9}$ ）	0	所有样本对均严格满足超可加性

首先，本文对所构建模型的超可加性进行了大规模的数值验证。实验从真实的资产池中随机抽取了 5000 对互不相交的投资组合 A 和 B ，分别计算它们作为独立组合的 $RS(A)$ 、 $RS(B)$ 以及合并后的 $RS(A \cup B)$ ，并据此计算差值 $RS(A \cup B) - [RS(A) + RS(B)]$ 。理论上，差值不小于 0 代表满足超可加性，考虑到计算的浮点误差，实验设置符合超可加性的阈值为 10^{-9} 。具体数值计算结果如表 4.2 所示。在全部 5000 次随机抽样中，差值的违例次数为 0，这意味着所有测试都满

足了超可加性条件。这一结果不仅在数值上证明了 RS 作为特征函数输入量子算法的合法性，也进一步强调了分散投资带来的风险节省效果。

其次，本文针对还原公式的无损转化特性进行了极高精度的数值验证。实验同验证超可加性一样，采用抽样方式得到一系列投资组合。接着分别采用两种互相独立的模式来计算各资产的夏普利风险贡献值 Φ_i^{SRC} ：第一种为直接基于 ES 定义，通过式 (4.6) 计算；第二种为“对偶-还原”模式，即对于 ES 再做一步转换得到 RS（定义 4.5）并通过式 (4.40) 计算 Φ_i^{RS} ，最后利用还原机制（定理 4.7）得到 Φ_i^{SRC} 。两种计算方式之间的绝对误差如图 4.6。所有资产的平均绝对误差仅为 5.64×10^{-18} 。即使误差最大的情况，即图 4.6 中涵盖了高、中、低三种不同风险等级资产的异构投资组合，两种计算方式的绝对误差仍然处于 10^{-17} 到 10^{-18} 的极小量级。从图中可以观察到，高风险资产（如 TWLO）的绝对误差略高于低风险资产（如 AGG），这主要是因为高风险资产自身的风险度量基数较大，在涉及多次加减操作的对偶转换过程中，受限于浮点数精度产生的舍入误差会随之微增。但总体而言，这种量级的误差相较于风险度量值本身而言完全可以忽略不计。这一结果说明了 Φ_i^{RS} 在实际数值计算时还原为 Φ_i^{SRC} 的截断误差是完全可以接受的，佐证了对偶模型的还原机制在实际市场数据下的无损性。




图 4.6 使用 ES 直接计算与使用 RS 间接计算之间的误差

综上所述，上述实验结果进一步验证了本文所提理论框架的正确性，表明该

理论能有效令量子算法能够适配风险归因计算任务。

4.5.4 算法性能分析

本节采用随机采样的形式，从全域资产池中进行多轮独立实验以评估量子算法的性能。实验流程为：

- 文中多次风险归因值、夏普利风险贡献、 Φ_i^{SRC} 混用

1. 从各个不同的风险池中按一定比例随机抽取资产形成投资组合，采样比例见表 4.3；

2. 利用经典蒙特卡洛采样算法、本文提出的量子算法计算各个资产在组合中的夏普利风险贡献；

3. 计算各方法求得的风险归因值与基准值的相对误差；

4. 如此重复多轮，得到当前变量环境下相对误差的平均值。
- 表 4.3 不同规模投资组合的资产采样配置
- | 投资组合资产总数 | 高、中、低风险资产数比例 |
|----------|--------------|
| 3 | 1:1:1 |
| 4 | 2:1:1 |
| 5 | 2:2:1 |
| 6 | 2:2:2 |
- 4.6 本章小结
- 65

参考文献

- [1] Vazquez A C. Anedumla/Quantum_linear_solvers[Z/OL]. 2026. https://github.com/anedumla/quantum_linear_solvers.
- [2] Lee Y, Joo J, Lee S. Hybrid Quantum Linear Equation Algorithm and Its Experimental Test on IBM Quantum Experience[J/OL]. Scientific Reports, 2019, 9(1): 4778. <https://www.nature.com/articles/s41598-019-41324-9>. DOI:10.1038/s41598-019-41324-9.
- [3] (美) David J G, (美) Darrell F S. 量子力学概论[M]. 英文注释版, 原书第 3 版. 北京市百万庄大街 22 号: 机械工业出版社, 2020.
- [4] (美) Michael A N, (美) Isaac L C. 量子计算与量子信息[M]. 孙晓明, 尚云, 李绿周, 等, 译. 10 周年版. 北京市万寿路南口金家村 288 号华信大厦: 电子工业出版社, 2022.
- [5] Shor P W. Algorithms for Quantum Computation: Discrete Logarithms and Factoring[C/OL]//Proceedings 35th Annual Symposium on Foundations of Computer Science. 1994: 124-134. <https://ieeexplore.ieee.org/document/365700>. DOI:10.1109/SFCS.1994.365700.
- [6] Grover L K. A Fast Quantum Mechanical Algorithm for Database Search[C/OL]//Proceedings of the Twenty-Eighth Annual ACM Symposium on Theory of Computing - STOC ' 96. Philadelphia, Pennsylvania, United States: ACM Press, 1996: 212-219. <http://portal.acm.org/citation.cfm?doid=237814.237866>. DOI:10.1145/237814.237866.
- [7] Harrow A W, Hassidim A, Lloyd S. Quantum Algorithm for Linear Systems of Equations[J/OL]. Physical Review Letters, 2009, 103(15): 150502. <https://link.aps.org/doi/10.1103/PhysRevLett.103.150502>. DOI:10.1103/PhysRevLett.103.150502.
- [8] 于瑞祺, 张鑫云, 任爽. 基于变分量子电路的量子机器学习算法综述[J/OL]. 计算机研究与发展, 2025(4): 821-851. <https://lib.cqvip.com/Qikan/Article/Detail?id=7200600095>.
- [9] Quinton F A, Myhr P A S, Barani M, et al. Quantum Annealing Applications, Challenges and Limitations for Optimisation Problems Compared to Classical

- Solvers[J/OL]. *Scientific Reports*, 2025, 15(1): 12733. <https://www.nature.com/articles/s41598-025-96220-2>. DOI:10.1038/s41598-025-96220-2.
- [10] Arute F, Arya K, Babbush R, et al. Quantum Supremacy Using a Programmable Superconducting Processor[J/OL]. *Nature*, 2019, 574(7779): 505-510. <https://www.nature.com/articles/s41586-019-1666-5>. DOI:10.1038/s41586-019-1666-5.
- [11] Zhong H S, Wang H, Deng Y H, et al. Quantum Computational Advantage Using Photons[J/OL]. *Science*, 2020, 370(6523): 1460-1463. <https://www.science.org/doi/10.1126/science.abe8770>. DOI:10.1126/science.abe8770.
- [12] U.S. Government. National Quantum Initiative[Z/OL]//National Quantum Initiative. <https://www.quantum.gov>.
- [13] Innovation F, Science, Canada E D. Canada's National Quantum Strategy[Z/OL]. Innovation, Science and Economic Development Canada, 2025. <https://ised-isde.canada.ca/site/national-quantum-strategy/en/canadas-national-quantum-strategy>.
- [14] Introduction to the Quantum Flagship[Z/OL]//Quantum Flagship. <https://qt.eu/about-quantum-flagship/>.
- [15] Yamamoto Y, Sasaki M, Takesue H. Quantum Information Science and Technology in Japan[J/OL]. *Quantum Science and Technology*, 2019, 4(2): 20502. <https://iopscience.iop.org/article/10.1088/2058-9565/ab0077>. DOI:10.1088/2058-9565/ab0077.
- [16] “十四五”规划和 2035 年远景目标纲要[Z/OL]//共产党员网. <https://www.12371.cn/special/ssw2035/>.
- [17] 中共中央关于制定国民经济和社会发展第十五个五年规划的建议[Z/OL]//共产党员网. <https://www.12371.cn/2025/10/28/ARTI1761640401107119.shtml>.
- [18] Herman D, Googin C, Liu X, et al. Quantum Computing for Finance[J/OL]. *Nature Reviews Physics*, 2023, 5(8): 450-465. <https://www.nature.com/articles/s42254-023-00603-1>. DOI:10.1038/s42254-023-00603-1.
- [19] Sedighi A, Jacobson D. Computational Challenges and Opportunities in Financial Services[C/OL]//Smart Computing and Communication: 4th International Conference, SmartCom 2019, Birmingham, UK, October 11 – 13, 2019, Proceedings. Berlin, Heidelberg: Springer-Verlag, 2019: 310-319. <https://doi.org/10.1007/978->

- 3-030-34139-8_31. DOI:10.1007/978-3-030-34139-8_31.
- [20] Xiang D, Jiang Q, Lu L, et al. Choco-Q: Commute Hamiltonian-Based QAOA for Constrained Binary Optimization[C/OL]//2025 IEEE International Symposium on High Performance Computer Architecture (HPCA). Las Vegas, NV, USA: IEEE, 2025: 275-289. <https://ieeexplore.ieee.org/document/10946294/>. DOI:10.1109/HPCA61900.2025.00031.
- [21] Jiang Q, Lu L, Xiang D, et al. Rasengan: A Transition Hamiltonian-Based Approximation Algorithm for Solving Constrained Binary Optimization Problems[C/OL]//Proceedings of the 2025 58th IEEE/ACM International Symposium on Microarchitecture. Seoul Korea: ACM, 2025: 764-777. <https://dl.acm.org/doi/10.1145/3725843.3756107>. DOI:10.1145/3725843.3756107.
- [22] Leclerc L, Ortiz-Gutiérrez L, Grijalva S, et al. Financial Risk Management on a Neutral Atom Quantum Processor[J/OL]. Physical Review Research, 2023, 5(4): 43117. <https://link.aps.org/doi/10.1103/PhysRevResearch.5.043117>. DOI:10.1103/PhysRevResearch.5.043117.
- [23] Innan N, Sawaika A, Dhor A, et al. Financial Fraud Detection Using Quantum Graph Neural Networks[J]. Quantum Machine Intelligence, 2024, 6.
- [24] Stamatopoulos N, Egger D J, Sun Y, et al. Option Pricing Using Quantum Computers[J/OL]. Quantum, 2020, 4: 291. <https://quantum-journal.org/papers/q-2020-07-06-291/>. DOI:10.22331/q-2020-07-06-291.
- [25] Zhang H, Wan L, Ramos-Calderer S, et al. Efficient Option Pricing with a Unary-Based Photonic Computing Chip and Generative Adversarial Learning[J/OL]. Photonics Research, 2023, 11(10): 1703. <https://opg.optica.org/abstract.cfm?URI=prj-11-10-1703>. DOI:10.1364/PRJ.493865.
- [26] Liu M, Shaydulin R, Niroula P, et al. Certified Randomness Using a Trapped-Ion Quantum Processor[J/OL]. Nature, 2025, 640(8058): 343-348. <https://www.nature.com/articles/s41586-025-08737-1>. DOI:10.1038/s41586-025-08737-1.
- [27] JPMorganChase, Quantinuum, Argonne National Laboratory, Oak Ridge National Laboratory and University of Texas at Austin Advance the Application of Quantum Computing to Potential Real-World Use Cases beyond the Capabilities of Classical Computing[Z/OL]//J.P. Morgan | Official Website. 2025. <https://www.jpmorgan.com/technology/news/certified-randomness>.

- [28] QC Ware. Goldman Sachs and QC Ware Collaboration Brings New Way to Price Risky Assets within Reach of Quantum Computers[Z/OL]//QC Ware. 2021. <https://www.qcware.com/news/goldman-sachs-and-qc-ware-collaboration-brings-new-way-to-price-risky-assets-within-reach-of-quantum-computers>.
- [29] HSBC Demonstrates World's First-Known Quantum-Enabled Algorithmic Trading with IBM[Z/OL]//HSBC news. 2025. <https://www.hsbc.com/news-and-views/news/media-releases/2025/hsbc-demonstrates-worlds-first-known-quantum-enabled-algorithmic-trading-with-ibm>.
- [30] 新华财经. 本源量子金融应用正式上线[Z/OL]//新华财经 - 中国金融信息网. 2022. https://www.cnfin.com/jgdt-lb/detail/20220130/3528023_1.html.
- [31] 中国工商银行. 工行成功应用千公里级量子通信技术[Z/OL]//中国工商银行中国网站. 2017. <https://www.icbc.com.cn/page/721852589322043404.html>.
- [32] 建信金融科技有限责任公司量子金融应用实验室. 技术应用 | 建设银行量子金融优化应用的探索与实践[Z/OL]//新浪财经. 2025. <https://t.cj.sina.com.cn/articles/view/7072825535/1a592c0bf00101a72s>.
- [33] Markowitz H. Portfolio Selection*[J/OL]. *Journal of Finance*, 1952, 7(1): 77-91. <https://onlinelibrary.wiley.com/doi/10.1111/j.1540-6261.1952.tb01525.x>. DOI:10.1111/j.1540-6261.1952.tb01525.x.
- [34] (美) Harry M M, (美) G Peter T. 资产组合选择和资本市场的均值-方差分析[M]. 黄涛, 译. 第 1 版. 北京市百万庄大街 22 号: 机械工业出版社, 2016.
- [35] Song X, Chen W, Lu J. Research on Financial Stock Market Prediction Based on the Hidden Quantum Markov Model[J/OL]. *Mathematics*, 2025, 13(15): 2505. <https://www.mdpi.com/2227-7390/13/15/2505>. DOI:10.3390/math13152505.
- [36] Ciceri A, Cottrell A, Freeland J, et al. Enhanced Fill Probability Estimates in Institutional Algorithmic Bond Trading Using Statistical Learning Algorithms with Quantum Computers[Z/OL]. arXiv, 2025. <http://arxiv.org/abs/2509.17715>. DOI:10.48550/arXiv.2509.17715.
- [37] Chen J H, Huang Y C, Tsai Y C, et al. Quantum-Enhanced Forecasting for Deep Reinforcement Learning in Algorithmic Trading[Z/OL]. arXiv, 2025. <http://arxiv.org/abs/2509.09176>. DOI:10.48550/arXiv.2509.09176.
- [38] Zhuang X N, Chen Z Y, Wu Y C, et al. Quantum Computational Quantitative

- Trading: High-Frequency Statistical Arbitrage Algorithm[J/OL]. *New Journal of Physics*, 2022, 24(7): 73036. <https://dx.doi.org/10.1088/1367-2630/ac7f26>. DOI:10.1088/1367-2630/ac7f26.
- [39] Nimbe P, Weyori B A, Adekoya A F. Models in Quantum Computing: A Systematic Review[J/OL]. *Quantum Information Processing*, 2021, 20(2). <https://doi.org/10.1007/s11128-021-03021-3>. DOI:10.1007/s11128-021-03021-3.
- [40] Brassard G, Høyer P, Mosca M, et al. Quantum Amplitude Amplification and Estimation[M/OL]//LOMONACO S J, BRANDT H E. *Contemporary Mathematics: Vol. 305*. Providence, Rhode Island: American Mathematical Society, 2002: 53-74. <http://www.ams.org/conm/305/>. DOI:10.1090/conm/305/05215.
- [41] Suzuki Y, Uno S, Raymond R, et al. Amplitude Estimation without Phase Estimation[J/OL]. *Quantum Information Processing*, 2020, 19(2): 75. <https://doi.org/10.1007/s11128-019-2565-2>. DOI:10.1007/s11128-019-2565-2.
- [42] Nakaji K. Faster Amplitude Estimation[J/OL]. *Quantum Information and Computation*, 2020, 20(13 & 14): 1109-1123. <http://www.rintonpress.com/journals/doi/QIC20.13-14-2.html>. DOI:10.26421/QIC20.13-14-2.
- [43] Grinko D, Gacon J, Zoufal C, et al. Iterative Quantum Amplitude Estimation[J/OL]. *npj Quantum Information*, 2021, 7(1): 52-57. <https://www.nature.com/articles/s41534-021-00379-1>. DOI:10.1038/s41534-021-00379-1.
- [44] Grant E, Humble T S, Stump B. Benchmarking Quantum Annealing Controls with Portfolio Optimization[J/OL]. *Physical Review Applied*, 2021, 15(1): 14012. <https://link.aps.org/doi/10.1103/PhysRevApplied.15.014012>. DOI:10.1103/PhysRevApplied.15.014012.
- [45] Brandhofer S, Braun D, Dehn V, et al. Benchmarking the Performance of Portfolio Optimization with QAOA[J/OL]. *Quantum Information Processing*, 2022, 22(1): 25. <https://doi.org/10.1007/s11128-022-03766-5>. DOI:10.1007/s11128-022-03766-5.
- [46] Buonaiuto G, Gargiulo F, De Pietro G, et al. Best Practices for Portfolio Optimization by Quantum Computing, Experimented on Real Quantum Devices[J/OL]. *Scientific Reports*, 2023, 13(1): 19434. <https://www.nature.com/articles/s41598-023-45392-w>. DOI:10.1038/s41598-023-45392-w.
- [47] Rebentrost P, Lloyd S. Quantum Computational Finance: Quantum Algorithm for

- Portfolio Optimization[J/OL]. *Künstliche Intelligenz*, 2024. <https://link.springer.com/10.1007/s13218-024-00870-9>. DOI:10.1007/s13218-024-00870-9.
- [48] Yalovetzky R, Minssen P, Herman D, et al. Solving Linear Systems on Quantum Hardware with Hybrid HHL++[J/OL]. *Scientific Reports*, 2024, 14(1): 20610. <https://www.nature.com/articles/s41598-024-69077-0>. DOI:10.1038/s41598-024-69077-0.
- [49] IBM Quantum. Introduction to Transpilation[Z/OL].//IBM Quantum Documentation. <https://quantum.cloud.ibm.com/docs/en/guides/quantum.cloud.ibm.com/docs/en/guides/transpile>.
- [50] Zhang M, Dong L, Zeng Y, et al. Improved Circuit Implementation of the HHL Algorithm and Its Simulations on QISKIT[J/OL]. *Scientific Reports*, 2022, 12(1): 13287. <https://www.nature.com/articles/s41598-022-17660-8>. DOI:10.1038/s41598-022-17660-8.
- [51] Iten R, Colbeck R, Kukuljan I, et al. Quantum Circuits for Isometries[J/OL]. *Physical Review A*, 2016, 93(3): 32318. <https://link.aps.org/doi/10.1103/PhysRevA.93.032318>. DOI:10.1103/PhysRevA.93.032318.
- [52] Wikipedia. Condition Number[J/OL]. Wikipedia, 2026. https://en.wikipedia.org/wiki/Condition_number.
- [53] Hestenes M R, Stiefel E. Methods of conjugate gradients for solving linear systems[J/OL]. *Journal of Research of the National Bureau of Standards*, 1952, 49(6): 409-436. DOI:10.6028/jres.049.044.
- [54] Braatz R D, Morari M. Minimizing the Euclidean Condition Number[J/OL]. *SIAM Journal on Control and Optimization*, 2006. <https://epubs.siam.org/doi/10.1137/S0363012992238680>. DOI:10.1137/S0363012992238680.
- [55] Nelder J A, Mead R. A Simplex Method for Function Minimization[J/OL]. *The Computer Journal*, 1965, 7(4): 308-313. <https://doi.org/10.1093/comjnl/7.4.308>. DOI:10.1093/comjnl/7.4.308.
- [56] Gao F, Han L. Implementing the Nelder-Mead Simplex Algorithm with Adaptive Parameters[J/OL]. *Computational Optimization and Applications*, 2012, 51(1): 259-277. <https://doi.org/10.1007/s10589-010-9329-3>. DOI:10.1007/s10589-010-9329-3.
- [57] Mestre X. Improved Estimation of Eigenvalues and Eigenvectors of Covariance

- Matrices Using Their Sample Estimates[J/OL]. *IEEE Transactions on Information Theory*, 2008, 54(11): 5113-5129. <https://ieeexplore.ieee.org/document/4655460>. DOI:10.1109/TIT.2008.929938.
- [58] Di Napoli E, Polizzi E, Saad Y. Efficient Estimation of Eigenvalue Counts in an Interval[J/OL]. *Numerical Linear Algebra with Applications*, 2016, 23(4): 674-692. <https://onlinelibrary.wiley.com/doi/abs/10.1002/nla.2048>. DOI:10.1002/nla.2048.
- [59] Somma R D. Quantum Eigenvalue Estimation via Time Series Analysis[J/OL]. *New Journal of Physics*, 2019, 21(12): 123025. <https://doi.org/10.1088/1367-2630/ab5c60>. DOI:10.1088/1367-2630/ab5c60.
- [60] Paiva F D, Cardoso R T N, Hanaoka G P, et al. Decision-Making for Financial Trading: A Fusion Approach of Machine Learning and Portfolio Selection[J/OL]. *Expert Systems with Applications*, 2019, 115: 635-655. <https://www.sciencedirect.com/science/article/pii/S0957417418305037>. DOI:10.1016/j.eswa.2018.08.003.
- [61] Zhou Z, Song Z, Xiao H, et al. Multi-Source Data Driven Cryptocurrency Price Movement Prediction and Portfolio Optimization[J/OL]. *Expert Systems with Applications*, 2023, 219: 119600. <https://www.sciencedirect.com/science/article/pii/S095741742300101X>. DOI:10.1016/j.eswa.2023.119600.
- [62] Silva N F, de Andrade L P, da Silva W S, et al. Portfolio Optimization Based on the Pre-Selection of Stocks by the Support Vector Machine Model[J/OL]. *Finance Research Letters*, 2024, 61: 105014. <https://www.sciencedirect.com/science/article/pii/S1544612324000448>. DOI:10.1016/j.frl.2024.105014.
- [63] Awad M, Khanna R. Support Vector Regression[M/OL]//AWAD M, KHANNA R. *Efficient Learning Machines: Theories, Concepts, and Applications for Engineers and System Designers*. Berkeley, CA: Apress, 2015: 67-80. https://doi.org/10.1007/978-1-4302-5990-9_4. DOI:10.1007/978-1-4302-5990-9_4.
- [64] Drucker H, Burges C J C, Kaufman L, et al. Support Vector Regression Machines[C/OL]//*Proceedings of the 10th International Conference on Neural Information Processing Systems*. Cambridge, MA, USA: MIT Press, 1996: 155-161. DOI:10.5555/2998981.2999003.
- [65] Quinlan J R. Induction of Decision Trees[J/OL]. *Machine Learning*, 1986, 1(1):

- 81-106. <https://doi.org/10.1007/BF00116251>. DOI:10.1007/BF00116251.
- [66] Rumelhart D E, Hinton G E, Williams R J. Learning Representations by Back-Propagating Errors[J/OL]. *Nature*, 1986, 323(6088): 533-536. <https://www.nature.com/articles/323533a0>. DOI:10.1038/323533a0.
- [67] Lecun Y, Bottou L, Bengio Y, et al. Gradient-Based Learning Applied to Document Recognition[J/OL]. *Proceedings of the IEEE*, 1998, 86(11): 2278-2324. <https://ieeexplore.ieee.org/document/726791>. DOI:10.1109/5.726791.
- [68] Harris C R, Millman K J, van der Walt S J, et al. Array Programming with NumPy[J/OL]. *Nature*, 2020, 585(7825): 357-362. <https://www.nature.com/articles/s41586-020-2649-2>. DOI:10.1038/s41586-020-2649-2.
- [69] Javadi-Abhari A, Treinish M, Krsulich K, et al. Quantum Computing with Qiskit[Z/OL]. *arXiv*, 2024. <http://arxiv.org/abs/2405.08810>. DOI:10.48550/arXiv.2405.08810.
- [70] Virtanen P, Gommers R, Oliphant T E, et al. SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python[J/OL]. *Nature Methods*, 2020, 17(3): 261-272. <https://www.nature.com/articles/s41592-019-0686-2>. DOI:10.1038/s41592-019-0686-2.
- [71] Pedregosa F, Varoquaux G, Gramfort A, et al. Scikit-Learn: Machine Learning in Python[J/OL]. *J. Mach. Learn. Res.*, 2011, 12: 2825-2830. <https://jmlr.org/papers/v12/pedregosa11a.html>. DOI:10.5555/1953048.2078195.
- [72] Google Quantum AI. Quantum Computer Datasheet[R/OL]. Google LLC, 2021. <https://quantumai.google/hardware/datasheet/weber.pdf>.
- [73] Cont R. Empirical Properties of Asset Returns: Stylized Facts and Statistical Issues[J/OL]. *Quantitative Finance*, 2001, 1(2): 223-236. <https://www.tandfonline.com/doi/abs/10.1080/713665670>. DOI:10.1080/713665670.
- [74] Embrechts P, McNeil A J, Straumann D. Correlation and Dependence in Risk Management: Properties and Pitfalls[M]//DEMPSTER M A H. *Risk Management: Value at Risk and Beyond*. Cambridge University Press, 2002: 176-223.
- [75] Shapley L S. 17. A Value for n-Person Games[M/OL]//KUHN H W, TUCKER A W. *Contributions to the Theory of Games, Volume II*. Princeton University Press, 2016: 307-318. <https://www.degruyterbrill.com/document/doi/10.1515/9781400881970-018/html>.

- [76] Castro J, Gómez D, Tejada J. Polynomial Calculation of the Shapley Value Based on Sampling[J/OL]. *Computers & Operations Research*, 2009, 36(5): 1726-1730. <https://linkinghub.elsevier.com/retrieve/pii/S0305054808000804>. DOI:10.1016/j.cor.2008.04.004.
- [77] Lundberg S M, Lee S I. A Unified Approach to Interpreting Model Predictions[C/OL]//*Proceedings of the 31st International Conference on Neural Information Processing Systems*. Red Hook, NY, USA: Curran Associates Inc., 2017: 4768-4777. <https://dl.acm.org/doi/10.5555/3295222.3295230>. DOI:10.5555/3295222.3295230.
- [78] Zhang J, Sun Q, Liu J, et al. Efficient Sampling Approaches to Shapley Value Approximation[J/OL]. *Proceedings of the ACM on Management of Data*, 2023, 1(1): 1-24. <https://dl.acm.org/doi/10.1145/3588728>. DOI:10.1145/3588728.
- [79] Dionne G, Duchesne P, Pacurar M. Intraday Value at Risk (IVaR) Using Tick-by-Tick Data with Application to the Toronto Stock Exchange[J/OL]. *Journal of Empirical Finance*, 2009, 16(5): 777-792. <https://www.sciencedirect.com/science/article/pii/S092753980900036X>. DOI:10.1016/j.jempfin.2009.05.005.
- [80] Huge B, Savine A. Differential Machine Learning[Z/OL]. arXiv, 2020. <http://arxiv.org/abs/2005.02347>. DOI:10.48550/arXiv.2005.02347.
- [81] Subadditivity[J/OL]. Wikipedia, 2025. <https://en.wikipedia.org/w/index.php?title=Subadditivity&oldid=1298207998>.
- [82] Superadditivity[J/OL]. Wikipedia, 2025. <https://en.wikipedia.org/w/index.php?title=Superadditivity&oldid=1277423372>.
- [83] Artzner P, Delbaen F, Eber J M, 等. Coherent Measures of Risk[J/OL]. *Mathematical Finance*, 1999, 9(3): 203-228. <https://onlinelibrary.wiley.com/doi/abs/10.1111/1467-9965.00068>. DOI:10.1111/1467-9965.00068.
- [84] Yamai Y, Yoshida T. Comparative Analyses of Expected Shortfall and Value-at-Risk: Their Estimation Error, Decomposition, and Optimization[J/OL]. *Monetary and Economic Studies*, 2002, 20(1): 87-121. <https://ideas.repec.org/a/ime/imemes/v20y2002i1p87-121.html>.
- [85] 詹原瑞, 刘俊梅. 基于 VaR 和 ES 的经济资本配置方法比较分析[J/OL]. *北京理工大学学报 (社会科学版)*, 2013(6): 46-50. <http://journal.bit.edu.cn/sk/cn/article/id/20130608>.

- [86] Acerbi C, Tasche D. On the Coherence of Expected Shortfall[J/OL]. *Journal of Banking & Finance*, 2002, 26(7): 1487-1503. <https://www.sciencedirect.com/science/article/pii/S0378426602002832>. DOI:10.1016/S0378-4266(02)00283-2.
- [87] 徐秋爽, 胡石清, 程细玉. Shapley 值特点及其局限的讨论[J]. *数学的实践与认知*, 2023, 43(4): 44-52.
- [88] Burge I, Barbeau M, Garcia-Alfaro J. Quantum Algorithms for Shapley Value Calculation[C/OL]//2023 IEEE International Conference on Quantum Computing and Engineering (QCE). Bellevue, WA, USA: IEEE, 2023: 1-9. <https://ieeexplore.ieee.org/document/10313772/>. DOI:10.1109/QCE57702.2023.00024.
- [89] 同济大学数学科学学院. 高等数学[M]. 第八版. 北京市西城区德外大街 4 号: 高等教育出版社, 2023.

作者简历

教育经历：

- 2023 年 9 月～2026 年 6 月：浙江大学攻读硕士学位
- 2019 年 9 月～2023 年 6 月：中国地质大学（武汉）攻读学士学位

攻读硕士学位期间主要的研究成果：

- Zhu T, Lu L, Chen J, et al. SAPO: Improving the Scalability and Accuracy of Quantum Linear Solver for Portfolio Optimization[C]//2025 62nd ACM/IEEE Design Automation Conference (DAC). IEEE, 2025: 1-7. （第一作者，CCF-A 类会议）
- Jiang Q, Lu L, Xiang D, et al. Rasengan: A Transition Hamiltonian-based Approximation Algorithm for Solving Constrained Binary Optimization Problems[C]//Proceedings of the 58th IEEE/ACM International Symposium on Microarchitecture (MICRO). 2025: 764-777. （第五作者，CCF-A 类会议）
- 基于量子技术的金融服务新型算法研究（青年科学家项目）——国家重点研发计划重点专项（项目学生骨干，负责具体任务制定、统筹、执行）

致 谢

朱天泽
于浙江大学软件学院
当前日期